SEGMENTASI PELANGGAN BERBASIS PERILAKU PEMBELIAN (RFM) PADA DATASET ONLINE RETAIL II MENGGUNAKAN CLASSICAL UNSUPERVISED MACHINE LEARNING

LAPORAN PROYEK
UJIAN TENGAH SEMESTER

KELOMPOK: ASIK

NURIHSAN FEBRIANTO
NIM. 231111759
RYAN RAFLY TANJUNG
NIM. 231111350
MUHAMMAD ALFISYAHRIN
NIM. 231112853

PROGRAM STUDI S-1 TEKNIK INFORMATIKA
FAKULTAS INFORMATIKA
UNIVERSITAS MIKROSKIL
MEDAN
2026

DAFTAR ISI

DAFTAR GAMBAR ..... **iii**
DAFTAR TABEL ..... **iv**
PEMBAGIAN TUGAS ..... **vi**
BAGIAN A. LAPORAN TEKNIS PROYEK **1**
Ikhtisar dan Ruang Lingkup Laporan 1
1. Kompleksitas dan Perumusan Masalah 2
1.1 Latar Belakang dan Pentingnya Masalah 2
1.2 Rumusan Masalah, Tujuan, dan Luaran 3
1.3 Kriteria Keberhasilan dan Batasan Proyek 3
1.4 Mengapa Masalah Ini Kompleks 4
1.5 Tantangan Utama 5
1.6 Pengembangan dan Penyempurnaan 5
2. Dataset dan Pemahaman Data 6
2.1 Sumber dan Identitas Dataset 6
2.2 Jumlah Data dan Deskripsi Fitur 6
2.3 Real-World atau Sintetis 8
2.4 Masalah Kualitas Data 8
2.5 Kompleksitas Dataset 8
3. Exploratory Data Analysis (EDA) dan Temuan Awal 9
3.1 Contoh Data dan Distribusi Fitur Transaksi 9
3.2 Histogram Fitur Numerik pada Level Pelanggan 10
3.3 Korelasi Antarfitur 11
3.4 Nilai Pelanggan, Frekuensi Pembelian, dan Tren Waktu 12
3.5 Temuan Penting EDA dan Dampaknya pada Preprocessing 13
4. Preprocessing Data 14
4.1 Pembersihan Data 14
4.2 Normalisasi, Standardisasi, dan Transformasi 15
4.3 Penanganan Missing Value, Outlier, dan Ketidakseimbangan 15
4.4 Pembagian Data dan Pencegahan Kebocoran Data 16
5. Initial Feature Engineering 17
6. Baseline dan Model Kandidat Awal 18
6.1 Baseline 18
6.2 Pemilihan Jumlah Cluster 18
6.3 Model Kandidat 20
6.4 Alasan Pemilihan Model 21
6.5 Konfigurasi Eksperimen 22
7. Rancangan Evaluasi 23
7.1 Pembagian Data dan Metode Validasi 23
7.2 Metrik Evaluasi dan Alasan Pemilihannya 23
7.3 Prosedur Uji Kestabilan 24
8. Hasil Awal dan Analisis 25
8.1 Hasil Baseline 25
8.2 Tabel Hasil Eksperimen Awal 27
8.3 Kestabilan dan Generalisasi 29
8.4 Dampak Fitur Tambahan dan Reduksi Dimensi 30
8.5 Segmentasi Kandidat dan Profil Segmen 32
8.6 Evaluasi terhadap Kriteria Keberhasilan 35
8.7 Analisis Hasil, Keterbatasan, dan Hal yang Perlu Diperbaiki 35

9. Teknologi yang Digunakan 36
10. Dokumentasi, Reprodusibilitas, dan Rencana Pasca-UTS 37
10.1 Dokumentasi dan Reprodusibilitas 37
10.2 Cara Menjalankan Ulang 38
10.3 Rencana Pengembangan Pasca-UTS 38
10.4 Keterlacakan Angka Laporan ke Notebook 40
11. Kesimpulan 41
12. Lampiran 41
Lampiran A. Cuplikan Kode Penting 41
Lampiran B. Grafik Tambahan 44
Lampiran C. Tabel Tambahan 46
DAFTAR PUSTAKA 48
BAGIAN B. TAUTAN 50

DAFTAR GAMBAR

Gambar 1. Distribusi Quantity dan Price (log10) pada transaksi penjualan serta jumlah baris per negara....10
Gambar 2. Histogram Recency, Frequency, dan Monetary: skala asli (biru) dan setelah log1p (jingga)....11
Gambar 3. Korelasi Spearman antar fitur pelanggan 12
Gambar 4. Kurva Lorenz Monetary, sebaran Frequency, dan tren bulanan pendapatan serta pelanggan aktif....13
Gambar 5. Pemilihan K pada K-Means: Elbow (inertia), Silhouette, Davies–Bouldin, dan Calinski–Harabasz 19
Gambar 6. Dendrogram Ward (dipotong pada 20 cabang terakhir) 20
Gambar 7. Grafik k-distance (k = 6) untuk memilih eps DBSCAN....20
Gambar 8. Strategi validasi: holdout dijaga untuk konfirmasi, CV dipakai untuk kestabilan....23
Gambar 9. Distribusi Silhouette per pelanggan dan per cluster pada baseline (K = 3) 26
Gambar 10. Scree plot dengan varians kumulatif dan loading PC1–PC3 pada fitur RFM+ 32
Gambar 11. Sebaran Recency, Frequency, dan Monetary per segmen (skala log) 33
Gambar 12. Indeks fitur per segmen terhadap rata-rata populasi (100 = sama dengan populasi) 34
Gambar 13. Proyeksi 2D PCA (± 70% varians) dan t-SNE (perplexity 30) pada fitur RFM+; warna = cluster K-Means K = 4....44
Gambar 14. Sensitivitas t-SNE terhadap perplexity (5, 30, 50) dan seed (42, 43)....45
Gambar 15. Proyeksi UMAP: titik kecil = data latih, titik bertepi hitam = holdout (transform) 45
Gambar 16. Galat rekonstruksi PCA terhadap jumlah komponen 46

DAFTAR TABEL

Tabel 1. Pembagian tugas anggota kelompok vi
Tabel 2. Peta kesesuaian komponen Milestone 1, bab laporan, dan butir format laporan 1
Tabel 3. Rumusan masalah, tujuan, target luaran, dan jenis pendekatan 3
Tabel 4. Kriteria keberhasilan yang ditetapkan kelompok 3
Tabel 5. Pengembangan dan penyempurnaan dari tahap awal 5
Tabel 6. Identitas dan struktur dataset 6
Tabel 7. Kamus data dan statistik fitur mentah 7
Tabel 8. Audit kualitas data mentah 8
Tabel 9. Lima baris pertama data mentah 9
Tabel 10. Statistik deskriptif fitur pada level pelanggan (n = 5.852) 11
Tabel 11. Temuan EDA dan implikasinya 13
Tabel 12. Jejak audit pembersihan transaksi 14
Tabel 13. Contoh data latih setelah preprocessing (fitur RFM) 15
Tabel 14. Keputusan penanganan masalah data 15
Tabel 15. Pencegahan kebocoran data 16
Tabel 16. Definisi fitur hasil rekayasa, alasan, dan dampak yang diharapkan 17
Tabel 17. Skewness fitur sebelum dan sesudah transformasi 18
Tabel 18. Hasil sweep K-Means (data latih, fitur RFM) 19
Tabel 19. Penyapuan eps DBSCAN berdasarkan kuantil k-distance 21
Tabel 20. Pengaruh pilihan linkage pada Hierarchical clustering (K = 4) 21
Tabel 21. Kelebihan, kelemahan, dan alasan pemilihan kandidat 21
Tabel 22. Konfigurasi terpusat eksperimen 22
Tabel 23. Audit strategi validasi 23
Tabel 24. Metrik evaluasi yang digunakan 24
Tabel 25. Ukuran dan karakteristik cluster baseline (K-Means K = 3, data latih; median dalam satuan asli) 25
Tabel 26. Tabel hasil eksperimen awal 27
Tabel 27. Ukuran cluster, kesepakatan partisi, dan waktu komputasi (data latih, fitur RFM) 29
Tabel 28. 5-Fold CV pada data latih (fitur RFM) 29
Tabel 29. Kestabilan terhadap inisialisasi (10 seed, data latih) 30
Tabel 30. Profil cluster K-Means K = 4 pada fitur RFM+ (median, satuan asli) 31
Tabel 31. Pemilihan jumlah komponen PCA melalui uji tugas hilir (RFM+, K = 4) 32
Tabel 32. Profil segmen kandidat (median dalam satuan asli) dan nama usulan 33
Tabel 33. Fitur yang paling membedakan segmen (η^2, log1p kecuali ReturnRate) 34
Tabel 34. Tindakan bisnis yang disarankan per segmen 35
Tabel 35. Evaluasi K-Means K = 4 terhadap kriteria keberhasilan 35
Tabel 36. Teknologi, pustaka, dan lingkungan pengembangan 36
Tabel 37. Dokumentasi dan reprodusibilitas eksperimen 37
Tabel 38. Rencana pasca-UTS menuju final project UAS 38
Tabel 39. Angka rujukan laporan dan lokasinya pada notebook 40
Tabel 40. Profil rata-rata segmen dalam satuan asli (K-Means K = 4) 46
Tabel 41. Galat rekonstruksi PCA pada RFM+ terstandarisasi 46
Tabel 42. Trustworthiness@10 proyeksi dua dimensi 47
Tabel 43. Daftar tautan proyek 50

PEMBAGIAN TUGAS

Pembagian tugas antaranggota kelompok pada pengerjaan Milestone 1 dirinci pada Tabel 1.

Tabel 1. Pembagian tugas anggota kelompok

NIM	Nama	Peran	Rincian pekerjaan
231111759	Nurihsan Febriato	Data Understanding, EDA, dan Feature Engineering	Perumusan masalah, pemahaman dataset, audit kualitas data, penyusunan kamus data, EDA, visualisasi, agregasi data pelanggan, pembentukan fitur RFM, dan analisis temuan awal (Bab 1–4).
231111350	Ryan Rafly Tanjung	Preprocessing, Pemodelan, dan Evaluasi	Pembersihan data, transformasi dan normalisasi, pembagian data, baseline K-Means, pengujian kandidat model, seleksi jumlah cluster, evaluasi hasil, dan pengujian kestabilan model (Bab 5–8).
231112853	Muhammad Alfisyahrin	Dokumentasi dan Pendukung Analisis	Visualisasi reduksi dimensi PCA/t-SNE/UMAP, dokumentasi eksperimen, penyusunan tabel hasil, perapian laporan, dan pemeriksaan konsistensi laporan dengan notebook (Bab 9–13).

BAGIAN A. LAPORAN TEKNIS PROYEK

Ikhtisar dan Ruang Lingkup Laporan

Laporan ini mendokumentasikan pekerjaan Milestone 1 (Ujian Tengah Semester) pada proyek segmentasi pelanggan toko ritel daring berbasis perilaku pembelian. Data yang digunakan adalah dataset *Online Retail II* (Chen, 2012), yaitu seluruh transaksi sebuah toko daring berbasis Inggris Raya selama dua tahun. Sesuai batasan Milestone 1, seluruh eksperimen memakai pendekatan *classical machine learning* tanpa label (*unsupervised clustering*) dan tidak memakai *deep learning* (DNN/CNN).

Sistematika laporan mengikuti format laporan yang ditetapkan (Cover, Bagian Awal, Bagian A Laporan Teknis Proyek, dan Bagian B Tautan), sedangkan isi teknis Bagian A disusun menurut sembilan komponen Milestone 1 (A–I). Tabel 2 memetakan keterkaitan antara komponen Milestone 1, bab dalam laporan ini, dan butir-butir pada format laporan.

Tabel 2. Peta kesesuaian komponen Milestone 1, bab laporan, dan butir format laporan

Komponen Milestone 1	Bab	Butir pada format laporan (Bagian A) yang dipenuhi
A. Problem formulation	1	Butir 1: kompleksitas masalah, tantangan utama, pengembangan dan penyempurnaan
B. Dataset dan data understanding	2	Butir 2: sumber, jumlah data, fitur, format, real-world/sintetis, kompleksitas dataset
C. EDA dan initial findings	3	Butir 3: distribusi, histogram fitur numerik, korelasi, contoh data, temuan EDA
D. Preprocessing	4	Butir 4: pembersihan, normalisasi, outlier/missing/ketidakseimbangan, pembagian data, pencegahan kebocoran
E. Initial feature engineering	5	Butir 4b (transformasi fitur) dan alasan serta dampaknya
F. Baseline dan initial candidate models	6	Butir 5a, 5c, 5d: jenis model, konfigurasi, alasan pemilihan
G. Evaluation design	7	Butir 6a dan 4e: metrik dan alasannya, pembagian data, validasi
H. Initial results and analysis	8	Butir 6b, 6d, 6e: nilai metrik, perbandingan skenario, analisis hasil
I. Documentation and next plan	9–10	Butir 7 (teknologi), serta dokumentasi, reprodusibilitas, dan rencana pasca-UTS
Pelengkap format	12–13, Bagian B	Butir 9 (lampiran), butir 10 (daftar pustaka), dan Bagian B (tautan)

Butir format laporan yang khusus untuk DNN/CNN (arsitektur lapisan, optimizer/*learning rate*/*batch size*/*epoch*, dua fitur unik, kurva *loss* dan akurasi) serta butir 8 (deployment dan video demo) tidak berlaku pada Milestone 1 karena batasan *classical machine learning*. Padanan yang relevan disajikan sebagai gantinya, yaitu konfigurasi hiperparameter, kurva seleksi jumlah cluster, dan uji kestabilan.

Ringkasan hasil. Dari 1.067.371 baris transaksi mentah diperoleh 776.579 baris penjualan sah yang diagregasi menjadi 5.852 pelanggan. Baseline K-Means (K = 3) pada fitur Recency–Frequency–Monetary (RFM) menghasilkan silhouette 0,346 pada data latih dan 0,356 pada data holdout. Kandidat terbaik sementara adalah K-Means dengan K = 4 (silhouette 0,365 pada data latih dan 0,376 pada holdout; Davies–Bouldin 0,939; ARI antar-fold 0,963 ± 0,041) yang membentuk empat segmen. Segmen bernilai tertinggi (19,0% pelanggan) menyumbang 71,5% total Monetary. Struktur segmen tergolong lemah (kontinum), sehingga pemilihan model final sengaja ditunda hingga tahap UAS.

1. Kompleksitas dan Perumusan Masalah

1.1 Latar Belakang dan Pentingnya Masalah

Toko daring yang menjadi objek proyek menjual perlengkapan hadiah untuk berbagai kesempatan dan, menurut deskripsi sumber data, banyak pelanggannya adalah pedagang grosir. Ketika seluruh pelanggan diperlakukan sama, anggaran promosi, program retensi, dan layanan pelanggan terbagi rata tanpa mempertimbangkan perbedaan nilai dan perilaku. Hasil EDA menunjukkan bahwa nilai antar pelanggan sangat timpang: 10% pelanggan teratas menyumbang 63,9% dan 20% teratas menyumbang 77,2% total nilai pembelian (koefisien Gini 0,74), sedangkan separuh pelanggan terbawah hanya menyumbang 6,5%. Pada kondisi demikian, perlakuan seragam berisiko memboroskan anggaran pada pelanggan bernilai rendah dan kurang melayani pelanggan bernilai tinggi.

Segmentasi pelanggan berbasis perilaku pembelian merupakan praktik yang lazim untuk menjawab persoalan tersebut, dan model RFM telah digunakan pada data ritel daring dari sumber yang sama (Chen et al., 2012). Proyek ini menerapkan pendekatan tersebut dengan fokus pada kualitas bukti: bagaimana struktur segmen dapat dibuktikan tanpa label, seberapa stabil hasilnya, dan apakah hasilnya dapat ditafsirkan oleh pemangku kepentingan bisnis.

1.2 Rumusan Masalah, Tujuan, dan Luaran

Tabel 3. Rumusan masalah, tujuan, target luaran, dan jenis pendekatan

Aspek	Uraian
Rumusan masalah	Kelompok pelanggan apa yang secara alami terbentuk pada data transaksi toko daring ini, dan bagaimana ciri perilaku pembelian masing-masing kelompok?
Tujuan penggunaan ML	Menemukan segmen pelanggan berbasis perilaku pembelian (*clustering*) agar promosi, retensi, dan layanan dapat dibedakan per segmen.
Target luaran	(1) Label segmen untuk setiap pelanggan; (2) profil tiap segmen dalam satuan asli (Recency, Frequency, Monetary) beserta nama usulan; (3) bukti kualitas segmentasi berupa metrik internal, kestabilan, dan konfirmasi pada data holdout.
Target (label)	Tidak ada. Tidak ada label "benar", sehingga hasil dinilai dengan metrik internal, kestabilan, dan interpretasi bisnis.
Unit analisis	1 observasi = 1 pelanggan (`CustomerID`). Data mentah berupa baris item faktur yang diagregasi per pelanggan (Bab 5).
Fitur	Fitur utama RFM. Varian RFM+ menambah jumlah produk unik, nilai rata-rata keranjang, dan rasio retur (Bab 5).
Jenis pendekatan	*Unsupervised learning*: *clustering* (K-Means, Hierarchical/Ward, GMM, DBSCAN), ditambah reduksi dimensi (PCA, t-SNE, UMAP) untuk uji redundansi dan visualisasi.
Pertanyaan kerja	Bukan "algoritma apa yang terbaik?", melainkan: masalah apa yang ingin diselesaikan, apakah data mendukung, dan seberapa baik baseline menyelesaikannya?

Sumber: Notebook, bagian A.

1.3 Kriteria Keberhasilan dan Batasan Proyek

Karena tidak ada label, tidak ada skor "benar" yang dapat dijadikan acuan. Kelompok karenanya menetapkan tiga kriteria keberhasilan sebelum eksperimen dijalankan, dan mengevaluasinya pada Bab 8.

Tabel 4. Kriteria keberhasilan yang ditetapkan kelompok

Kriteria	Indikator dan ambang	Dievaluasi di
Stabil	ARI ≥ 0,8 antar-fold dan antar-subsampel	Bagian 8.3 dan 8.6
Bukan artefak	Silhouette ≥ 0,26 pada data latih **dan** holdout (batas bawah pita "lemah" menurut Kaufman & Rousseeuw, 1990)	Bagian 8.3 dan 8.6

Kriteria	Indikator dan ambang	Dievaluasi di
Dapat ditafsirkan	Tidak ada segmen mikro (< 1% pelanggan) tanpa alasan bisnis; nama dan tindakan segmen divalidasi pemangku kepentingan	Bagian 8.5 dan 8.6

Sumber: Notebook, bagian A dan L2.

Batasan proyek yang berlaku adalah sebagai berikut.

1. Hanya *classical machine learning* tak terawasi (K-Means, Hierarchical, GMM, DBSCAN, PCA); tidak memakai *deep learning*.
2. Dataset dan masalah terkunci dan tidak diganti demi performa model; perubahan yang diperlukan harus disertai alasan dan persetujuan dosen.
3. Hanya pelanggan teridentifikasi (`CustomerID` terisi); tamu tanpa ID berada di luar cakupan (22,8% baris data mentah).
4. Satu periode data (Desember 2009 – Desember 2011), 91,9% baris berasal dari United Kingdom, dan tidak ada *ground truth*.
5. Lingkup UTS adalah baseline, kandidat awal, validasi, dan temuan awal. Tuning menyeluruh, *error analysis* lengkap, dan model final merupakan pekerjaan tahap UAS.

1.4 Mengapa Masalah Ini Kompleks

1. **Tanpa label dan tanpa *ground truth*.** Mutu hasil tidak dapat diukur dengan akurasi atau F1. Evaluasi harus memakai metrik internal (Silhouette, Davies–Bouldin, Calinski–Harabasz), kestabilan (ARI), dan interpretasi bisnis, yang masing-masing memiliki kelemahan bila dipakai sendirian.
2. **Distribusi sangat miring dengan banyak outlier.** Skewness Monetary 25,33 dan Frequency 12,04; 10,6% pelanggan merupakan outlier Monetary menurut aturan IQR. Pelanggan grosir besar bersifat nyata dan bernilai bisnis sehingga tidak boleh dibuang, tetapi mendistorsi jarak Euclidean bila tidak ditransformasi.
3. **Data transaksional harus diagregasi ke level pelanggan.** Sebanyak 1.067.371 baris item-faktur harus menjadi 5.852 observasi pelanggan. Kekeliruan pembersihan (duplikat, retur, kode non-produk) langsung menggelembungkan Frequency dan Monetary.
4. **Masalah kualitas data.** 22,8% baris tanpa `CustomerID`, 3,2% duplikat persis, 1,8% faktur pembatalan, kode non-produk, serta nilai `Quantity` atau `Price` ≤ 0.
5. **Perilaku pelanggan membentuk kontinum.** Silhouette hanya 0,346–0,365 (kategori lemah), sehingga batas antar segmen tidak tegas.
6. **Redundansi fitur.** Korelasi Spearman Frequency–Monetary 0,86, dan pada varian RFM+ nilai keranjang rata-rata hampir kolinear dengan Monetary dan Frequency.

7. **Jumlah cluster bersifat subjektif.** K = 2 unggul pada seluruh metrik internal tetapi hanya memisahkan pelanggan aktif dari tidak aktif, terlalu kasar untuk keputusan bisnis.

1.5 Tantangan Utama

1. Merancang evaluasi yang jujur tanpa label, yaitu membedakan struktur nyata data dari artefak algoritma.
2. Mencegah kebocoran data walaupun tidak ada variabel target: *scaler* dan PCA hanya di-*fit* pada data latih, validasi silang memfit ulang di tiap *fold*, dan holdout hanya untuk konfirmasi.
3. Memilih jumlah cluster secara bijak dengan menggabungkan Elbow, Silhouette, Davies–Bouldin, Calinski–Harabasz, dan kebermaknaan bisnis.
4. Menjamin kestabilan segmentasi terhadap perubahan sampel, *fold*, dan inisialisasi acak.
5. Menghasilkan segmen yang dapat ditafsirkan dan ditindaklanjuti oleh tim pemasaran.
6. Menyadari batas generalisasi: satu periode data dan dominasi pasar United Kingdom.

1.6 Pengembangan dan Penyempurnaan

Tabel 5 merangkum bagian yang ditambah, diperbaiki, atau diganti dari konfigurasi awal (baseline) menuju rancangan eksperimen pada laporan ini.

Tabel 5. Pengembangan dan penyempurnaan dari tahap awal

Aspek	Tahap awal (baseline)	Penyempurnaan pada Milestone 1
Jumlah cluster	K = 3 ditetapkan tanpa bukti	Seleksi K (2–10) dengan Elbow, Silhouette, Davies–Bouldin, dan Calinski–Harabasz; konsensus peringkat pada K ∈ [3, 8] menghasilkan K = 4
Algoritma	K-Means saja	Ditambah Hierarchical (empat *linkage*), GMM, dan DBSCAN
Fitur	RFM (3 fitur)	Varian RFM+ (6 fitur) dan uji redundansi dengan PCA
Validasi	Metrik internal pada data latih	Holdout 20%, 5-Fold CV, 10 *seed*, dan 10 subsampel 80% untuk kestabilan
Preprocessing	Pembersihan dasar	Pembersihan dengan jejak audit tiap langkah; `log1p` dan `StandardScaler` di dalam `Pipeline` yang di-*fit* hanya pada data latih

Aspek	Tahap awal (baseline)	Penyempurnaan pada Milestone 1
Dokumentasi	Catatan ad hoc	*Seed* eksplisit, `requirements.txt`, sidik jari data, log eksperimen, *model card*, dan uji konsistensi antar-*run*

Sumber: Notebook, bagian D, G, H, dan K.

2. Dataset dan Pemahaman Data

2.1 Sumber dan Identitas Dataset

Tabel 6. Identitas dan struktur dataset

Aspek	Isi
Nama dan sumber resmi	*Online Retail II*, UCI Machine Learning Repository (ID 502): https://archive.ics.uci.edu/dataset/502/online+retail+ii
Sitasi	Chen, D. (2012). *Online Retail II* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5CG6D
Lisensi	CC BY 4.0 (boleh dipakai dengan atribusi).
Salinan yang dipakai	Kaggle `adilhabib/online-retail-data-clustering`, berkas `online_retail_II.xlsx` (45,6 MB pada salinan ini; ±43,5 MB pada UCI). Jumlah baris dan rentang tanggal identik dengan deskripsi UCI.
Format dan jumlah data	Berkas Excel (`.xlsx`) dengan dua lembar tahun yang digabung; 1.067.371 baris dan 8 kolom.
Periode	1 Desember 2009 s.d. 9 Desember 2011.
Unit observasi	1 baris = 1 item produk pada 1 faktur. Unit analisis proyek = 1 pelanggan (agregasi per `CustomerID`).
Target	Tidak ada (*unsupervised*).
Cara memperoleh	Otomatis lewat `kagglehub`; bila gagal, unduh dari UCI atau Kaggle, unggah ke `/content`, atau isi `CFG["LOCAL_PATH"]`. Berkas tidak disertakan karena ukurannya besar.

Sumber: Notebook, bagian B dan K1c (manifest data).

Isi dataset adalah seluruh transaksi sebuah toko daring terdaftar di Inggris Raya tanpa toko fisik. Toko ini terutama menjual perlengkapan hadiah untuk berbagai kesempatan, dan banyak pelanggannya adalah pedagang grosir (Chen, 2012).

2.2 Jumlah Data dan Deskripsi Fitur

Dataset memuat 1.067.371 baris dan 8 fitur mentah, dengan 53.628 faktur unik, 5.942 pelanggan unik (`CustomerID` terisi), 5.304 produk unik, dan 43 negara. Tabel 7 merupakan kamus data beserta peran tiap fitur dalam proyek.

Tabel 7. Kamus data dan statistik fitur mentah

Fitur	Deskripsi	Tipe	N unik	Hilang (%)	Rentang	Peran dalam proyek
Invoice	Nomor faktur; awalan "C" menandai pembatalan (retur)	object	53.628	0	–	Frequency = jumlah faktur unik; pemisah retur
StockCode	Kode produk; sebagian berupa kode non-produk (POST, DOT, M, dst.)	object	5.304	0	–	UniqueProducts; filter non-produk
Description	Nama produk (teks bebas)	object	5.698	0,41	–	Tidak dipakai sebagai fitur
Quantity	Jumlah unit per baris; negatif pada retur/koreksi	int64	1.057	0	−80.995 s.d. 80.995	Monetary = Quantity × Price
InvoiceDate	Tanggal dan jam faktur	datetime	47.635	0	2009-12-01 s.d. 2011-12-09	Recency (jarak ke SNAPSHOT); tren waktu
Price	Harga satuan dalam poundsterling (GBP); ≤ 0 bukan penjualan	float64	2.807	0	−53.594,36 s.d. 38.970	Monetary = Quantity × Price
CustomerID	ID pelanggan (kunci agregasi); kosong = tanpa ID	Int64	5.942	22,77	12.346 s.d. 18.287	Unit analisis
Country	Negara tempat pelanggan berada	object	43	0	–	Hanya EDA/konteks

Sumber: Notebook, bagian B6. Deskripsi mengacu pada dokumentasi UCI; statistik dihitung dari data.

2.3 Real-World atau Sintetis

Dataset bersifat **real-world**. UCI menggambarkannya sebagai data transaksi ritel daring nyata selama dua tahun. Konsekuensinya, data memuat ketidaksempurnaan khas dunia nyata, yaitu ID pelanggan kosong, duplikat, pembatalan, kode non-produk, dan nilai ekstrem dari pesanan grosir, yang harus ditangani secara eksplisit pada tahap preprocessing.

2.4 Masalah Kualitas Data

Tabel 8. Audit kualitas data mentah

Isu kualitas	Jumlah baris	Persen	Penanganan
`CustomerID` kosong	243.007	22,767%	Dibuang; tidak dapat diagregasi per pelanggan
Baris duplikat persis	34.335	3,217%	Dibuang; menggandakan Frequency/Monetary
Faktur pembatalan (awalan C)	19.494	1,826%	Dipisahkan sebagai data retur
`Quantity` ≤ 0	22.950	2,150%	Dikeluarkan dari penjualan; retur dipisahkan
`Price` ≤ 0	6.207	0,582%	Dikeluarkan dari penjualan
`Description` kosong	4.382	0,411%	Dibiarkan; kolom tidak dipakai sebagai fitur
`StockCode` non-produk	3.660*	0,343%*	Dibuang; bukan perilaku belanja produk
Outlier `Quantity` (IQR, penjualan)	111.341	10,689%	Dipertahankan; ditangani `log1p` setelah agregasi
Outlier `Price` (IQR, penjualan)	81.634	7,837%	Dipertahankan; ditangani `log1p` setelah agregasi

*Sumber: Notebook, bagian B2–B4 dan C1. *Dihitung terhadap data setelah duplikat dan ID kosong dibuang (794.225 dari 797.885 baris); persentase terhadap 1.067.371 baris. Persentase outlier dihitung terhadap transaksi penjualan.*

2.5 Kompleksitas Dataset

Dataset tergolong kompleks karena beberapa alasan. Pertama, skalanya lebih dari satu juta baris dengan unit observasi (item faktur) yang berbeda dari unit analisis (pelanggan). Kedua, fitur numerik mentah sangat miring: skewness `Quantity` 459,99 dan `Price` 231,44, dengan nilai maksimum `Quantity` 80.995 berbanding median 3. Ketiga, sekitar 22,8% baris tidak dapat dikaitkan dengan pelanggan. Keempat, terdapat kode non-produk, pembatalan, dan nilai tidak valid yang harus dipisahkan agar tidak mencemari Monetary. Kelima, data memiliki dimensi waktu dengan pola musiman,

sementara 91,9% baris berasal dari satu negara. Terakhir, tidak ada label sehingga kualitas segmentasi harus dibuktikan secara tidak langsung.

3. Exploratory Data Analysis (EDA) dan Temuan Awal

EDA bersifat deskriptif dan tidak mempelajari parameter dari data sehingga memakai seluruh pelanggan tanpa risiko kebocoran data. Karena proyek ini tidak memiliki label dan bukan data teks atau citra, komponen EDA berupa distribusi label/kelas, *word count*, dan contoh gambar per kelas tidak berlaku. Padanannya adalah distribusi fitur numerik, korelasi antarfitur, dan contoh baris data.

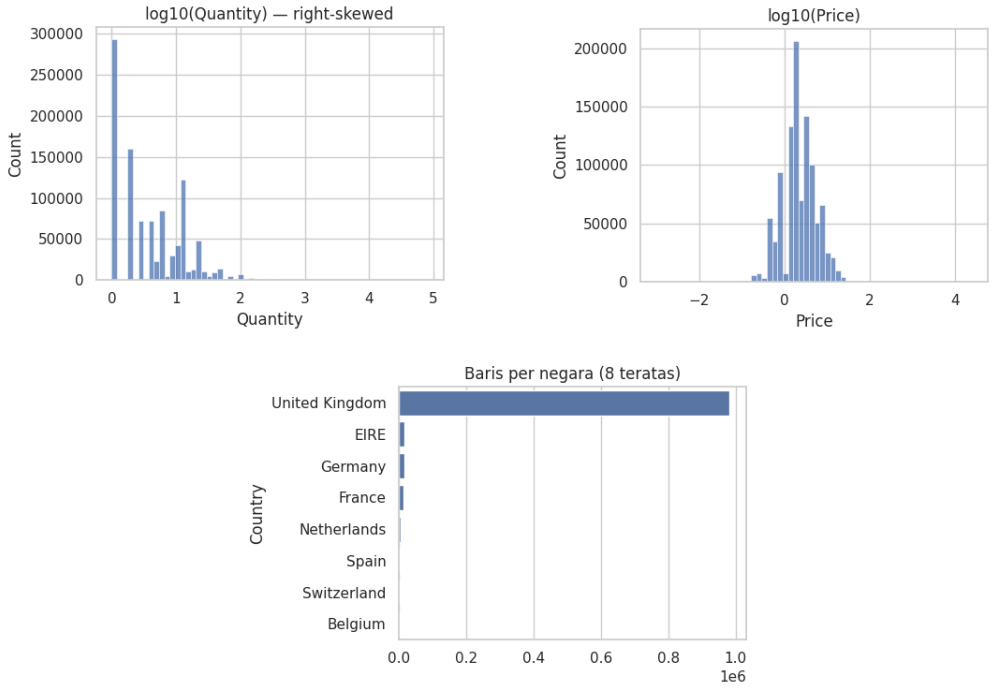
3.1 Contoh Data dan Distribusi Fitur Transaksi

Tabel 9. Lima baris pertama data mentah

Invoice	Stock Code	Description	Qty	InvoiceDate	Price	Customer ID	Country
489434	85048	15CM CHRISTMAS GLASS BALL 20 LIGHTS	12	2009-12-01 07:45	6,95	13085	United Kingdom
489434	79323P	PINK CHERRY LIGHTS	12	2009-12-01 07:45	6,75	13085	United Kingdom
489434	79323W	WHITE CHERRY LIGHTS	12	2009-12-01 07:45	6,75	13085	United Kingdom
489434	22041	RECORD FRAME 7" SINGLE SIZE	48	2009-12-01 07:45	2,10	13085	United Kingdom
489434	21232	STRAWBERRY CERAMIC TRINKET BOX	24	2009-12-01 07:45	1,25	13085	United Kingdom

Sumber: Notebook, bagian B (keluaran `raw.head()`).

Gambar 1 memperlihatkan distribusi `Quantity` dan `Price` pada transaksi penjualan (skala logaritmik) serta jumlah baris per negara. Pada transaksi penjualan, `Quantity` memiliki rata-rata 10,96, median 3, persentil ke-99 sebesar 100, dan maksimum 80.995; `Price` memiliki rata-rata 4,08, median 2,10, dan maksimum 25.111,09. Selisih besar antara rata-rata dan median menegaskan distribusi miring ke kanan akibat pesanan grosir. United Kingdom menyumbang 91,9% baris, diikuti EIRE, Jerman, dan Prancis dengan porsi jauh lebih kecil.

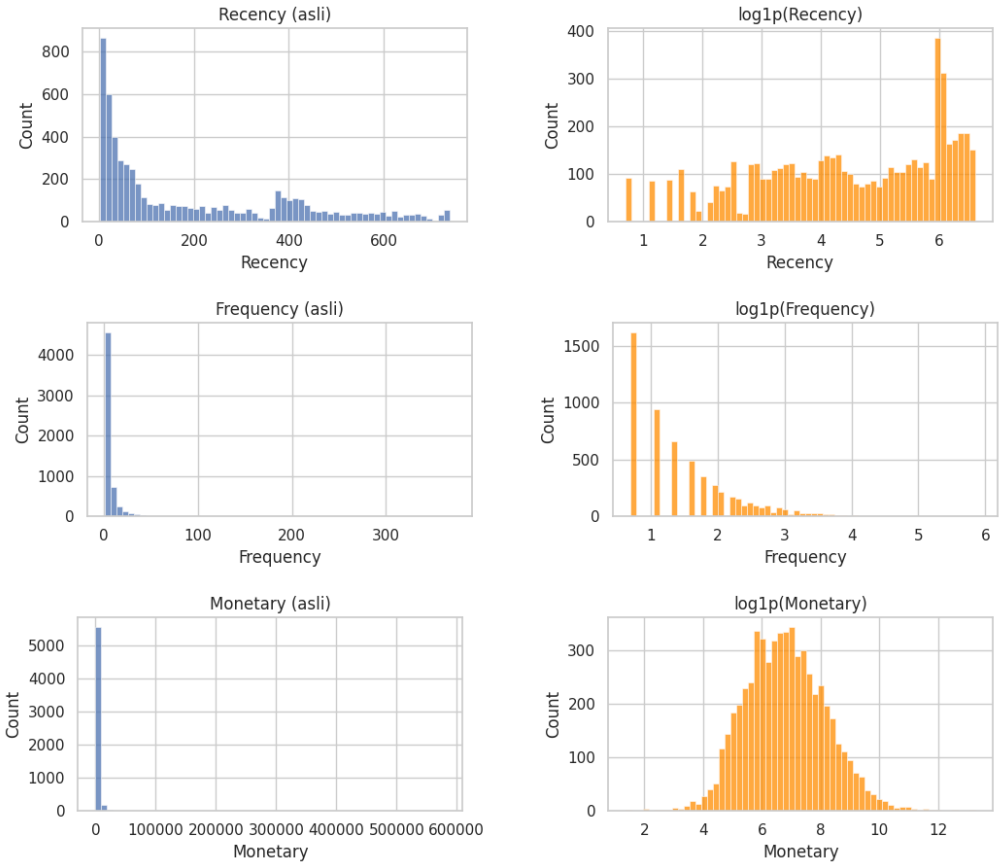


Gambar 1. Distribusi Quantity dan Price (log10) pada transaksi penjualan serta jumlah baris per negara

Sumber: Notebook, bagian B4.

3.2 Histogram Fitur Numerik pada Level Pelanggan

Setelah agregasi ke level pelanggan diperoleh 5.852 pelanggan. Tabel 10 meringkas statistik deskriptif fitur pelanggan, dan Gambar 2 membandingkan histogram RFM sebelum dan sesudah transformasi `log1p`. Frequency dan Monetary berekor sangat panjang pada skala asli: Monetary bernilai maksimum 580.987 berbanding median 856, sedangkan 99% pelanggan berada di bawah 28.631. Setelah `log1p`, Monetary mendekati simetris, sedangkan Frequency tetap memiliki ekor kanan karena nilainya diskret dan banyak pelanggan hanya membeli satu atau dua kali.



Gambar 2. Histogram Recency, Frequency, dan Monetary: skala asli (biru) dan setelah log1p (jingga)

Sumber: Notebook, bagian C2.

Tabel 10. Statistik deskriptif fitur pada level pelanggan (n = 5.852)

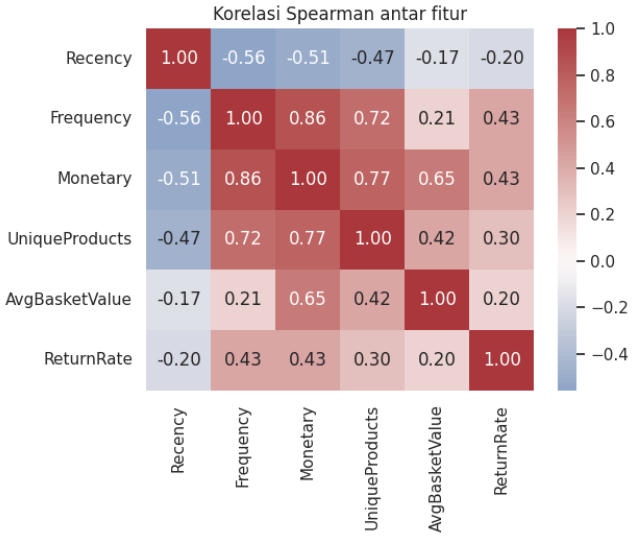
Fitur	Rata-rata	Std	Min	Q1	Median	Q3	P95	P99	Maks
Recency (hari)	200,2	208,5	1	25	95	379	623,5	726	739
Frequency	6,25	12,75	1	1	3	7	20	46	373
Monetary (GBP)	2.917	14.307	2,95	340	856	2.241	9.270	28.631	580.987
UniqueProducts	82,2	116,5	1	19	45	103	281	503	2.546
AvgBasketValue	384	1.255	2,95	176	278	411	871	1.907	84.236
ReturnRate	0,024	0,086	0	0	0	0,015	0,102	0,395	1

Sumber: Notebook, bagian C2 (keluaran `cust.describe()`); nilai besar dibulatkan.

3.3 Korelasi Antarfitur

Gambar 3 menyajikan korelasi Spearman antar fitur pelanggan. Pasangan paling berkorelasi adalah Frequency–Monetary (0,86), diikuti Monetary–UniqueProducts (0,77) dan Frequency–UniqueProducts (0,72). Recency berkorelasi negatif dengan ketiganya

(−0,56 terhadap Frequency, −0,51 terhadap Monetary, dan −0,47 terhadap UniqueProducts), yang berarti pelanggan yang baru bertransaksi cenderung sering dan bernilai besar. AvgBasketValue berkorelasi 0,65 dengan Monetary, sedangkan ReturnRate hanya berkorelasi sedang (0,43) dengan Frequency dan Monetary. Tingginya korelasi menunjukkan bahwa RFM sebagian redundan sehingga segmen cenderung mencerminkan "tingkat aktivitas".

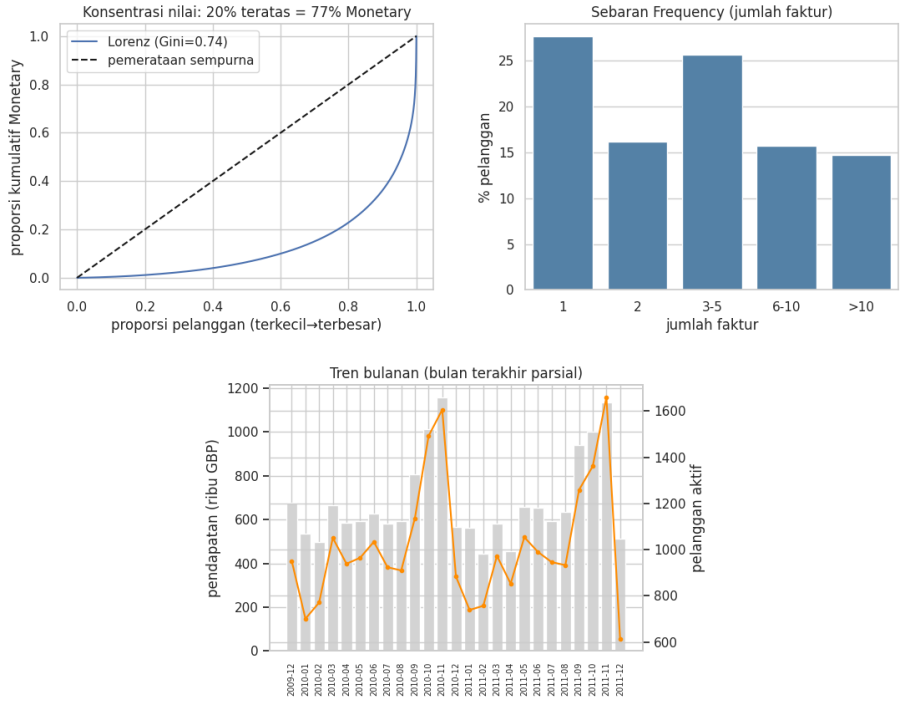


Gambar 3. Korelasi Spearman antar fitur pelanggan

Sumber: Notebook, bagian C2.

3.4 Nilai Pelanggan, Frekuensi Pembelian, dan Tren Waktu

Gambar 4 memuat kurva Lorenz nilai pelanggan, sebaran Frequency, dan tren bulanan. Konsentrasi nilai tinggi: 20% pelanggan teratas menyumbang 77,2% total Monetary (Gini 0,74). Sebanyak 27,6% pelanggan hanya membeli satu kali (median Frequency = 3), dan 40,7% pelanggan tidak bertransaksi lebih dari 180 hari (median Recency 95 hari). Pendapatan bulanan memuncak pada November 2010 sebesar 1,9 kali median bulan lengkap, yang mengindikasikan pola musiman; bulan terakhir (Desember 2011) bersifat parsial.



Gambar 4. Kurva Lorenz Monetary, sebaran Frequency, dan tren bulanan pendapatan serta pelanggan aktif

Sumber: Notebook, bagian C2b.

3.5 Temuan Penting EDA dan Dampaknya pada Preprocessing

Rekonsiliasi data: dari 5.942 pelanggan pada data mentah, 5.852 pelanggan memiliki setidaknya satu penjualan sah dan dianalisis. Sembilan puluh pelanggan lainnya tidak dianalisis karena seluruh barisnya berupa retur, nilai tidak valid, atau kode non-produk (100% baris milik pelanggan tersebut), sehingga wajar tidak disegmentasi. Tabel 11 merangkum temuan EDA dan implikasinya.

Tabel 11. Temuan EDA dan implikasinya

Temuan	Bukti	Implikasi untuk preprocessing/pemodelan
Nilai pelanggan sangat timpang	10% teratas = 63,9% dan 20% teratas = 77,2% Monetary; Gini 0,74; 50% terbawah hanya 6,5%	Segmentasi berbasis nilai bermakna bisnis; nilai ekstrem dipertahankan dan ditangani `log1p`, bukan dibuang
Pembelian berulang rendah	27,6% pelanggan hanya membeli sekali; median Frequency 3; skew 12,04 → 1,00 setelah `log1p`	`log1p` layak dipakai sebelum penskalaan

Temuan	Bukti	Implikasi untuk preprocessing/pemodelan
Banyak pelanggan tidak aktif	40,7% pelanggan tidak bertransaksi > 180 hari; median Recency 95 hari	Recency bergantung pada tanggal acuan global (keterbatasan); berpotensi membentuk segmen sendiri
Pola musiman	Pendapatan bulanan tertinggi pada 2010-11 (1,9× median bulan lengkap)	Musiman dapat memengaruhi Recency/Frequency; fitur musiman belum dibuat (rencana lanjutan)
Fitur sebagian redundan	Spearman Frequency–Monetary 0,86	Diuji lewat PCA dan varian fitur
Dominasi satu negara	91,9% baris dari United Kingdom	Hasil belum tentu berlaku untuk pasar lain (keterbatasan)

Sumber: Notebook, bagian C2b-2.

4. Preprocessing Data

Langkah preprocessing ditentukan oleh hasil audit data pada Bab 2 dan 3, bukan dipilih secara umum. Seluruh aturan pembersihan bersifat deterministik, sedangkan parameter yang dipelajari dari data (rata-rata dan simpangan baku *scaler*, serta PCA) hanya di-*fit* pada data latih.

4.1 Pembersihan Data

Tabel 12. Jejak audit pembersihan transaksi

Langkah	Alasan (bukti audit)	Baris tersisa	Baris dibuang
Data mentah	–	1.067.371	–
Hapus duplikat persis	Menggandakan transaksi sehingga Frequency/Monetary menggelembung (3,2%)	1.033.036	34.335
Hapus baris tanpa CustomerID, tanggal, Quantity, atau Price	Unit analisis adalah pelanggan; tanpa ID tidak dapat diagregasi (22,8%)	797.885	235.151
Hapus StockCode non-produk	Ongkos kirim, biaya, dan penyesuaian bukan perilaku belanja produk	794.225	3.660

Langkah	Alasan (bukti audit)	Baris tersisa	Baris dibuang
Pisahkan pembatalan (awalan C) serta Quantity ≤ 0 dan Price ≤ 0	Retur bukan pembelian; hanya dipakai untuk fitur ReturnRate	776.579 (penjualan sah)	17.646

Sumber: Notebook, bagian C1. Kode non-produk: POST, DOT, M, C2, C3, D, S, BANK CHARGES, ADJUST, ADJUST2, AMAZONFEE, CRUK, B, TEST001, TEST002, PADS. Dari 17.646 baris yang dikeluarkan, 17.586 baris retur (`Price` > 0) disimpan terpisah untuk ReturnRate; 60 baris sisanya tidak memenuhi syarat penjualan maupun retur.

Secara keseluruhan, 290.792 baris (27,2%) dikeluarkan dari data mentah sehingga tersisa 776.579 baris penjualan sah untuk 5.852 pelanggan.

4.2 Normalisasi, Standardisasi, dan Transformasi

Fitur pelanggan sangat miring dan berskala sangat berbeda (Recency dalam hari, Monetary dalam GBP hingga ratusan ribu). K-Means, GMM, dan PCA berbasis jarak atau varians sehingga akan didominasi fitur berskala besar bila tidak diskalakan. Preprocessing karenanya terdiri atas dua tahap dalam satu `Pipeline`: (1) transformasi `log1p` pada seluruh fitur kecuali ReturnRate yang sudah berada pada rentang [0, 1]; (2) `StandardScaler` yang di-*fit* hanya pada data latih. Setelah tahap ini, tiap fitur pada data latih memiliki rata-rata 0 dan simpangan baku 1 (Tabel 13). Transformasi `log1p` dipilih karena mampu menurunkan kemiringan secara drastis (Tabel 17 pada Bab 5).

Tabel 13. Contoh data latih setelah preprocessing (fitur RFM)

CustomerID	Recency	Frequency	Monetary
15778	1,041	−1,060	−0,783
15668	0,605	−1,060	−1,783
18156	−1,159	−0,559	−0,216
15786	−0,382	0,299	1,612
12461	0,388	−1,060	−0,270

Sumber: Notebook, bagian C3. Dimensi data latih: 4.681 × 3.

4.3 Penanganan Missing Value, Outlier, dan Ketidakseimbangan

Tabel 14. Keputusan penanganan masalah data

Isu	Keputusan	Alasan
Missing `CustomerID`	Baris dibuang (235.151 baris pada langkah ini)	Pelanggan tidak dapat diidentifikasi sehingga tidak dapat disegmentasi; keterbatasan dicatat

Isu	Keputusan	Alasan
Missing `Description`	Dibiarkan	Kolom tidak dipakai sebagai fitur sehingga tidak memengaruhi hasil
Nilai hilang pada fitur turunan	Tidak ada; ReturnRate = 0 bila pelanggan tak memiliki retur	Fitur turunan dihitung dari baris sah sehingga lengkap
Outlier (619 pelanggan, 10,6% menurut IQR Monetary)	Dipertahankan; ditangani `log1p`	Pelanggan grosir besar nyata dan bernilai bisnis; membuangnya menghilangkan segmen terpenting
Ketidakseimbangan kelas	Tidak berlaku; yang diperiksa adalah keseimbangan ukuran cluster	Bukan masalah klasifikasi; cluster kecil dengan Monetary besar adalah segmen bernilai
Augmentasi data	Tidak dipakai	Data tabular tak terawasi; augmentasi tidak relevan

Sumber: Notebook, bagian C dan C2.

4.4 Pembagian Data dan Pencegahan Kebocoran Data

Pelanggan dibagi secara acak menjadi 80% data latih (4.681 pelanggan) dan 20% data holdout (1.171 pelanggan) dengan `random_state = 42`. Walaupun tidak ada variabel target, pembagian tetap dilakukan agar dapat diuji apakah segmen berlaku pada pelanggan yang tidak ikut dipakai membentuk model. Tabel 15 merangkum penanganan risiko kebocoran data.

Tabel 15. Pencegahan kebocoran data

Aspek	Perlakuan
Aturan pembersihan	Deterministik (tidak mempelajari parameter dari data) dan dilakukan sebelum pembagian; bukan sumber kebocoran.
***Scaler* dan PCA**	Di-*fit* hanya pada data latih di dalam `Pipeline`; data holdout hanya di-*transform* atau di-*predict*.
Seleksi K dan metode	Memakai data latih (dan 5-Fold CV di dalam data latih); holdout tidak dipakai untuk memilih K atau algoritma.
Validasi silang	`Pipeline` dipelajari ulang pada tiap *fold-train*; pelanggan yang sama tidak mungkin muncul di dua *fold* karena 1 baris = 1 pelanggan.
Holdout	Dipakai hanya untuk konfirmasi akhir (baseline dan K-Means terpilih), tidak dipakai berulang.

Aspek	Perlakuan
Tanggal acuan Recency (`SNAPSHOT`)	Satu-satunya konstanta global, yaitu tanggal transaksi terakhir + 1 hari (2011-12-10), dihitung dari seluruh data penjualan. Dicatat sebagai keterbatasan.

Sumber: Notebook, bagian C (status leakage), C3, dan H1.

5. Initial Feature Engineering

Data mentah berada pada level baris faktur, sedangkan masalah berada pada level pelanggan. Fitur karenanya dibentuk melalui agregasi per `CustomerID`. Tanggal acuan Recency adalah 10 Desember 2011 (tanggal transaksi terakhir + 1 hari). Baseline hanya memakai tiga fitur RFM; tiga fitur tambahan diuji sebagai varian (RFM+) dan tidak menggantikan baseline.

Tabel 16. Definisi fitur hasil rekayasa, alasan, dan dampak yang diharapkan

Fitur	Definisi (per pelanggan)	Alasan	Dampak yang diharapkan
Recency	Hari dari pembelian terakhir ke tanggal acuan	Indikator keaktifan dan retensi	Memisahkan pelanggan aktif dari tidak aktif
Frequency	Jumlah faktur unik (penjualan sah)	Indikator loyalitas	Memisahkan pembeli sekali dari pelanggan setia
Monetary	Total Quantity × Price (penjualan sah)	Nilai finansial pelanggan	Memisahkan pelanggan bernilai tinggi (mis. grosir)
UniqueProducts	Jumlah StockCode berbeda	Keluasan belanja	Menambah dimensi perilaku di luar RFM
AvgBasketValue	Monetary ÷ Frequency	Ukuran keranjang belanja	Membedakan pelanggan ber-Monetary sama namun berpola berbeda
ReturnRate	Nilai retur ÷ Monetary (dibatasi 0–1)	Perilaku retur sebagai indikator risiko/biaya	Memunculkan segmen kecil dengan retur tinggi
Transformasi	`log1p` (kecuali ReturnRate), lalu `StandardScaler` dalam `Pipeline`	Skew tinggi dan skala berbeda jauh	Mengurangi dominasi outlier dan fitur berskala besar pada jarak Euclidean

Sumber: Notebook, bagian C2.

Dampak aktual transformasi diukur pada Tabel 17. `log1p` menurunkan skewness Monetary dari 25,33 menjadi 0,27, Frequency dari 12,04 menjadi 1,00, dan

AvgBasketValue dari 53,38 menjadi 0,06. ReturnRate tetap miring (8,10) karena mayoritas pelanggan tidak memiliki retur; hal ini menjadi keterbatasan varian RFM+. Dampak penambahan fitur terhadap partisi dibahas pada bagian 8.4.

Tabel 17. Skewness fitur sebelum dan sesudah transformasi

Fitur	Skewness asli	Skewness setelah transformasi	Perubahan
Recency	0,894	−0,486	Berkurang
Frequency	12,040	1,002	Berkurang drastis
Monetary	25,331	0,269	Berkurang drastis
UniqueProducts	6,221	−0,257	Berkurang drastis
AvgBasketValue	53,381	0,063	Berkurang drastis
ReturnRate	8,096	8,096	Tidak diubah (tanpa log1p)

Sumber: Notebook, bagian C2.

6. Baseline dan Model Kandidat Awal

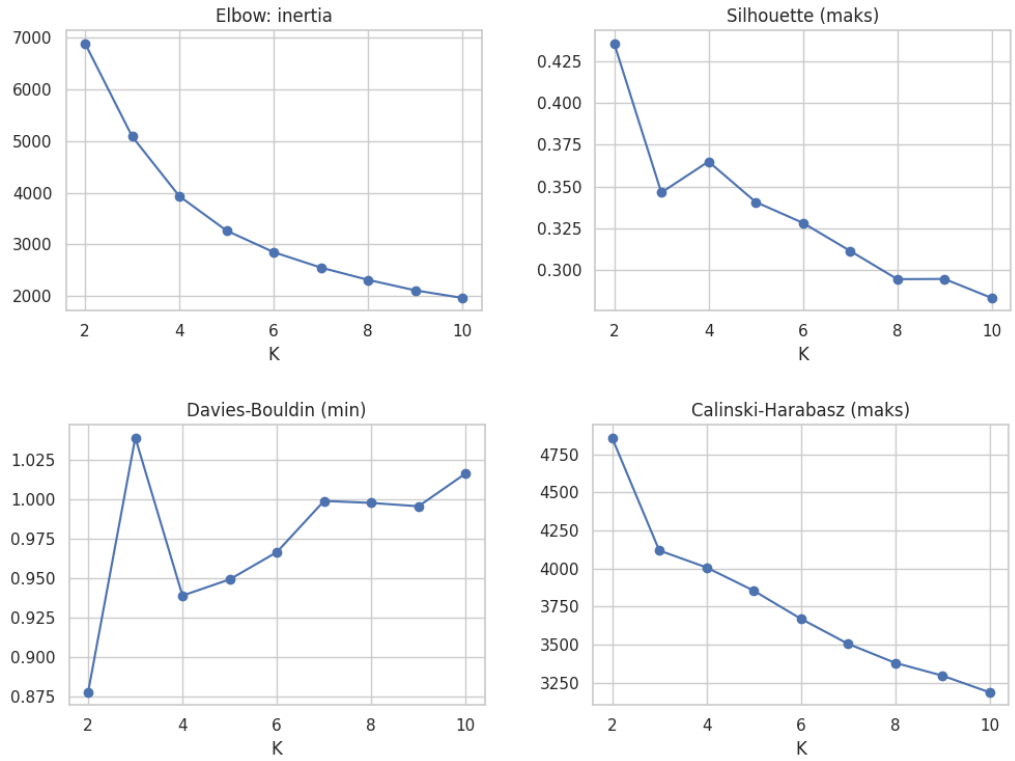
Seluruh model pada Milestone 1 adalah algoritma *classical machine learning* tak terawasi, sehingga pemilihan jenis model DNN atau CNN tidak berlaku. Model final belum diwajibkan pada tahap ini.

6.1 Baseline

Baseline adalah **K-Means dengan konfigurasi awal** (K = 3, `init = "k-means++"`, `n_init = 10`, `random_state = 42`) pada fitur RFM yang telah di-`log1p` dan di-*scale*. K-Means dipilih karena merupakan praktik standar segmentasi RFM, cepat, dan mudah dijelaskan (Arthur & Vassilvitskii, 2007). Nilai K = 3 sengaja belum dioptimalkan; tujuan baseline bukan menjadi model terbaik, melainkan menjawab seberapa baik struktur segmen dapat ditemukan sebelum pengembangan lebih lanjut. Baseline konvergen dalam 12 iterasi (0,11 detik) dengan inertia 5.086,7.

6.2 Pemilihan Jumlah Cluster

Jumlah cluster dicari pada K = 2 sampai 10 (Gambar 5 dan Tabel 18). Elbow tidak tegas, sebagaimana lazim pada data perilaku. Silhouette, Davies–Bouldin, dan Calinski–Harabasz seluruhnya memilih K = 2, tetapi pemisahan tersebut hanya "aktif vs tidak aktif" dan terlalu kasar untuk segmentasi bisnis. Pemilihan karenanya dibatasi pada rentang yang masih dapat ditindaklanjuti bisnis, $K \in [3, 8]$, dengan konsensus rata-rata peringkat tiga metrik. Hasilnya K* = 4 (rata-rata peringkat 1,333), diikuti K = 5 (2,667) dan K = 3 (3,000). Keputusan ini terdokumentasi, dan K = 2 tetap dilaporkan sebagai alternatif. K* = 4 merupakan kandidat untuk eksperimen, bukan keputusan final.



Gambar 5. Pemilihan K pada K-Means: Elbow (inertia), Silhouette, Davies–Bouldin, dan Calinski–Harabasz

Sumber: Notebook, bagian G1.

Tabel 18. Hasil sweep K-Means (data latih, fitur RFM)

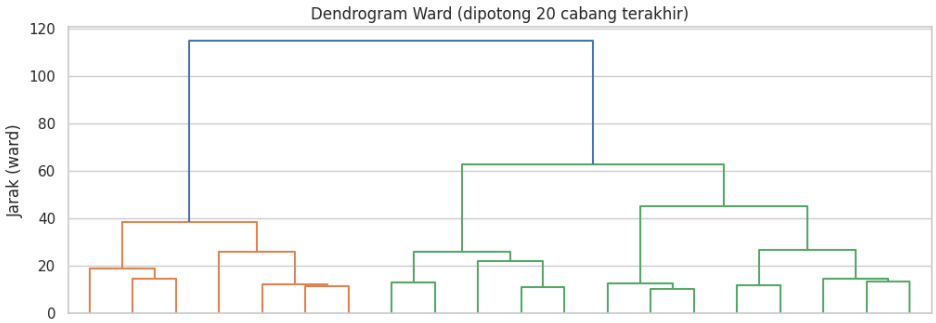
K	Inertia	Silhouette	Davies–Bouldin	Calinski–Harabasz	Cluster terkecil (%)	Rata-rata peringkat
2	6.888,3	0,436	0,878	4.859,9	39,3	–
3	5.086,7	0,346	1,039	4.118,4	20,0	3,000
4	3.933,5	0,365	0,939	4.006,9	19,1	1,333
5	3.268,1	0,341	0,949	3.854,2	8,3	2,667
6	2.851,6	0,328	0,967	3.669,5	7,9	3,667
7	2.553,8	0,312	0,999	3.504,6	5,1	5,000
8	2.316,5	0,295	0,998	3.379,5	5,7	5,333
9	2.114,0	0,295	0,996	3.295,4	5,2	–
10	1.967,3	0,284	1,016	3.185,7	4,8	–

Sumber: Notebook, bagian G1. Peringkat dihitung hanya untuk K ∈ [3, 8]; baris K = 4 (K) diberi warna.*

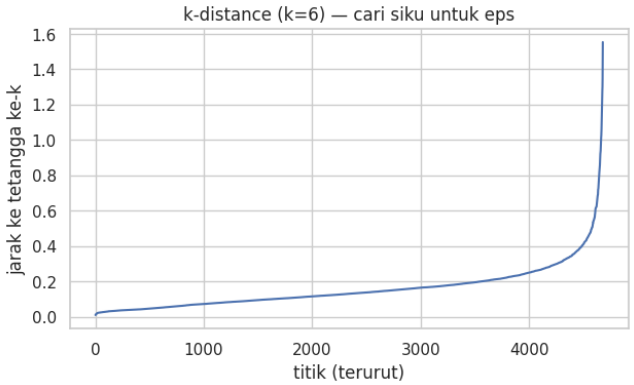
6.3 Model Kandidat

Selain baseline dan K-Means ber-K* = 4, diuji tiga kandidat dengan asumsi bentuk cluster berbeda. Seluruh metrik internal dihitung pada ruang fitur yang sama (RFM log + scaled) agar sebanding.

1. **Hierarchical (Ward).** Penggabungan bertahap yang meminimalkan kenaikan varians dalam cluster (Ward, 1963); tidak bergantung inisialisasi acak dan menghasilkan dendrogram (Gambar 6). Jumlah cluster disamakan dengan K* = 4. Pengaruh *linkage* diuji pada Tabel 20.
2. **Gaussian Mixture Model (GMM).** Model probabilistik dengan `covariance_type = "full"`, `n_init = 3`, dan K = 4, diestimasi dengan algoritma EM (Dempster et al., 1977); relevan karena batas segmen pelanggan cenderung kabur sehingga keanggotaan *soft* berguna.
3. **DBSCAN.** Algoritma berbasis kerapatan tanpa K yang mendeteksi *noise* (Ester et al., 1996). Nilai `min_samples` = 6 (dua kali jumlah fitur) dan `eps` dipilih dari grafik k-distance (Gambar 7 dan Tabel 19).



Gambar 6. Dendrogram Ward (dipotong pada 20 cabang terakhir)
Sumber: Notebook, bagian G2.



Gambar 7. Grafik k-distance (k = 6) untuk memilih eps DBSCAN
Sumber: Notebook, bagian G2.

Tabel 19. Penyapuan eps DBSCAN berdasarkan kuantil k-distance

Kuantil	eps	Jumlah cluster	Noise (%)	Silhouette (non-noise)
0,80	0,216	17	12,519	−0,044
0,90	0,289	6	5,683	0,057
0,95	0,373	2	2,841	0,277
0,98	0,519	1	1,090	tidak terdefinisi

Sumber: Notebook, bagian G2. eps terpilih = 0,373, yaitu yang memenuhi syarat ≥ 2 cluster dan noise ≤ 10% dengan silhouette tertinggi (baris diberi warna).

Tabel 20. Pengaruh pilihan linkage pada Hierarchical clustering (K = 4)

Linkage	Silhouette	Davies–Bouldin	Cluster terkecil (%)	Cluster terbesar (%)	ARI vs K-Means K=4	Waktu (s)
ward	0,306	0,938	14,185	33,711	0,642	0,62
complete	0,206	1,209	5,213	41,957	0,218	0,60
average	0,317	0,780	0,513	72,314	0,260	0,69
single	0,115	0,652	0,021	99,872	0,000	0,17

Sumber: Notebook, bagian G3b. Linkage average dan single membentuk cluster mikro (< 1%) akibat chaining, sehingga tidak cocok untuk segmentasi bisnis; Ward dipertahankan sebagai wakil Hierarchical.

6.4 Alasan Pemilihan Model

Tabel 21. Kelebihan, kelemahan, dan alasan pemilihan kandidat

Model	Kelebihan	Kelemahan	Alasan dipilih untuk data RFM ini
K-Means	Cepat, sederhana, dapat diskalakan	Perlu K; asumsi cluster bulat; sensitif outlier dan inisialisasi	Praktik standar segmentasi RFM dan mudah dijelaskan; dipakai sebagai baseline dan kandidat
Ward	Tanpa inisialisasi acak; ada dendrogram	Memori $O(n^2)$; tidak ada `predict` untuk data baru	Menguji apakah partisi bergantung pada algoritma, tanpa inisialisasi acak
GMM	Keanggotaan probabilistik; bentuk elips	Lebih lambat; asumsi Gaussian	Batas segmen cenderung kabur sehingga keanggotaan *soft* relevan untuk pelanggan di perbatasan

Model	Kelebihan	Kelemahan	Alasan dipilih untuk data RFM ini
DBSCAN	Tanpa K; mendeteksi noise	Sensitif eps; sulit pada kerapatan beragam	Memeriksa bentuk non-bulat dan pelanggan ekstrem (grosir) tanpa menetapkan K

Sumber: Notebook, bagian G (setelah G5).

6.5 Konfigurasi Eksperimen

Karena model tidak dilatih secara iteratif dengan *optimizer*, konfigurasi pelatihan pada format laporan digantikan oleh konfigurasi hiperparameter dan prosedur eksperimen pada Tabel 22.

Tabel 22. Konfigurasi terpusat eksperimen

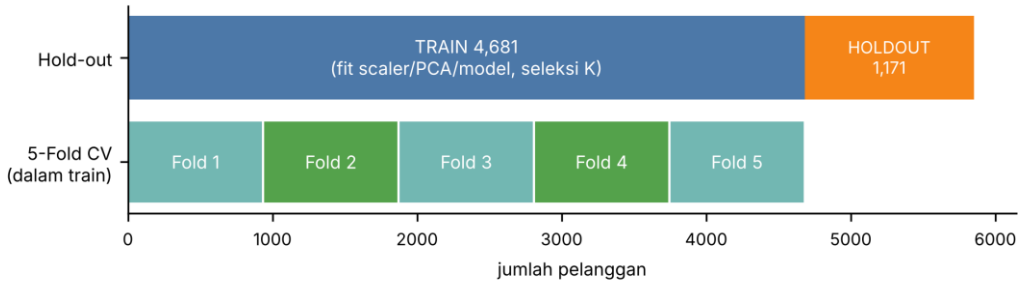
Parameter	Nilai	Fungsi
`RANDOM_STATE`	42	*Seed* eksplisit pada pembagian data, K-Means, GMM, PCA, t-SNE, UMAP, dan subsampel
`TEST_SIZE`	0,20	Porsi pelanggan holdout
`K_MIN` – `K_MAX`	2 – 10	Rentang pencarian K
`K_BUSINESS`	(3, 8)	Rentang K yang dapat ditindaklanjuti bisnis
`BASELINE_K`	3	K awal baseline
`N_FOLDS`	5	Jumlah *fold* validasi silang
`N_SEEDS`	10	Jumlah *seed* pada uji kestabilan inisialisasi
`N_SUBSAMPLE` × `SUBSAMPLE_FRAC`	10 × 0,8	Jumlah pasangan subsampel dan porsi pelanggan per subsampel
`TSNE_MAX_POINTS`	3.000	Jumlah titik maksimum untuk visualisasi t-SNE
K-Means	k-means++, n_init = 10	Inisialisasi dan jumlah percobaan ulang (n_init = 20 pada pipeline kandidat akhir)
DBSCAN `min_samples`	6	2 × jumlah fitur RFM

Sumber: Notebook, bagian 0 (CFG), G2, dan J1.

7. Rancangan Evaluasi

7.1 Pembagian Data dan Metode Validasi

Rancangan evaluasi disusun agar sesuai dengan karakteristik data tak terawasi (Gambar 8 dan Tabel 23). Data latih dipakai untuk *fit* dan seleksi, validasi silang 5-*fold* di dalam data latih dipakai untuk menilai kestabilan, dan holdout dijaga untuk konfirmasi sehingga tidak dipakai berulang.



Gambar 8. Strategi validasi: holdout dijaga untuk konfirmasi, CV dipakai untuk kestabilan

Sumber: disusun ulang dari diagram Notebook bagian H1 (angka identik) dengan ukuran huruf disesuaikan.

Tabel 23. Audit strategi validasi

Pertanyaan	Jawaban
Bagaimana data dibagi?	Pelanggan dibagi acak 80% latih dan 20% holdout (`random_state = 42`). Data latih dipakai untuk *fit* dan seleksi; holdout hanya untuk konfirmasi.
Perlu validation set?	Ya, untuk memilih K dan metode. Dipenuhi oleh 5-Fold CV di dalam data latih sehingga holdout tidak dipakai berulang.
Sesuai jenis masalah?	Tak terawasi sehingga tanpa stratifikasi; dipakai `KFold` acak per pelanggan.
Preprocessing hanya dari data latih?	Ya. `log1p` dan `StandardScaler` berada di `Pipeline` dan dipelajari ulang pada tiap *fold-train*.
Keterbatasan	Tanggal acuan Recency bersifat global. Tidak ada label sehingga tidak ada kebocoran target.

Sumber: Notebook, bagian H1.

7.2 Metrik Evaluasi dan Alasan Pemilihannya

Metrik klasifikasi (akurasi, presisi, *recall*, F1) dan metrik regresi (MAE, RMSE, R^2) tidak dapat dipakai karena tidak ada label. Evaluasi memakai tiga metrik internal dari sudut pandang berbeda, ditambah ukuran kestabilan.

Tabel 24. Metrik evaluasi yang digunakan

Metrik	Arah / rentang	Peran dan alasan
Silhouette (Rousseeuw, 1987)	−1 s.d. 1; makin besar makin baik	Mengukur kohesi terhadap separasi; mudah ditafsirkan. Pita menurut Kaufman & Rousseeuw (1990): ≥ 0,71 kuat; 0,51–0,70 wajar; 0,26–0,50 lemah; < 0,26 tidak ada struktur berarti.
Davies–Bouldin (1979)	≥ 0; makin kecil makin baik	Membandingkan sebaran dalam cluster dengan jarak antar pusat.
Calinski–Harabasz (1974)	≥ 0; makin besar makin baik	Rasio varians antar terhadap dalam cluster. Bergantung jumlah sampel, sehingga tidak sebanding antara data latih dan holdout.
Adjusted Rand Index (Hubert & Arabie, 1985)	−1 s.d. 1; 1 = identik	Mengukur kestabilan dan kesepakatan antar partisi; tidak terpengaruh penomoran cluster (von Luxburg, 2010).
Inertia	≥ 0	Dasar Elbow; selalu turun saat K naik sehingga tidak dipakai sendirian.
Eta-squared (η^2)	0 s.d. 1	Porsi variasi fitur yang dijelaskan segmen; ambang efek Cohen (1988): 0,06 sedang dan 0,14 besar.

Sumber: Notebook, bagian E, H1, dan J1b. Metrik eksternal (ARI/NMI terhadap label) tidak dipakai karena tidak ada label.

Silhouette, Davies–Bouldin, dan Calinski–Harabasz hanya sebanding antar model yang menggunakan ruang fitur yang sama. Perbandingan lintas ruang fitur (misalnya RFM terhadap RFM+ atau ruang PCA) dilakukan melalui kestabilan, ARI antar partisi, profil cluster, dan kebermaknaan bisnis.

7.3 Prosedur Uji Kestabilan

1. **Subsampel.** Dua subsampel acak independen (80% pelanggan) di-*cluster* terpisah, lalu ARI dihitung pada titik yang beririsan; diulang 10 kali.
2. **5-Fold CV.** `Pipeline` dilatih pada *fold-train*, lalu partisi pada *fold* validasi dibandingkan dengan model data latih penuh menggunakan ARI.
3. **Multi-*seed*.** K-Means dijalankan dengan 10 *seed* berbeda pada tiga skema inisialisasi untuk mengukur ketergantungan terhadap inisialisasi acak.
4. **Holdout.** Model K-Means terpilih diterapkan pada pelanggan holdout; Silhouette dan Davies–Bouldin dibandingkan dengan data latih, dan komposisi cluster antar-bagian diperiksa.

8. Hasil Awal dan Analisis

8.1 Hasil Baseline

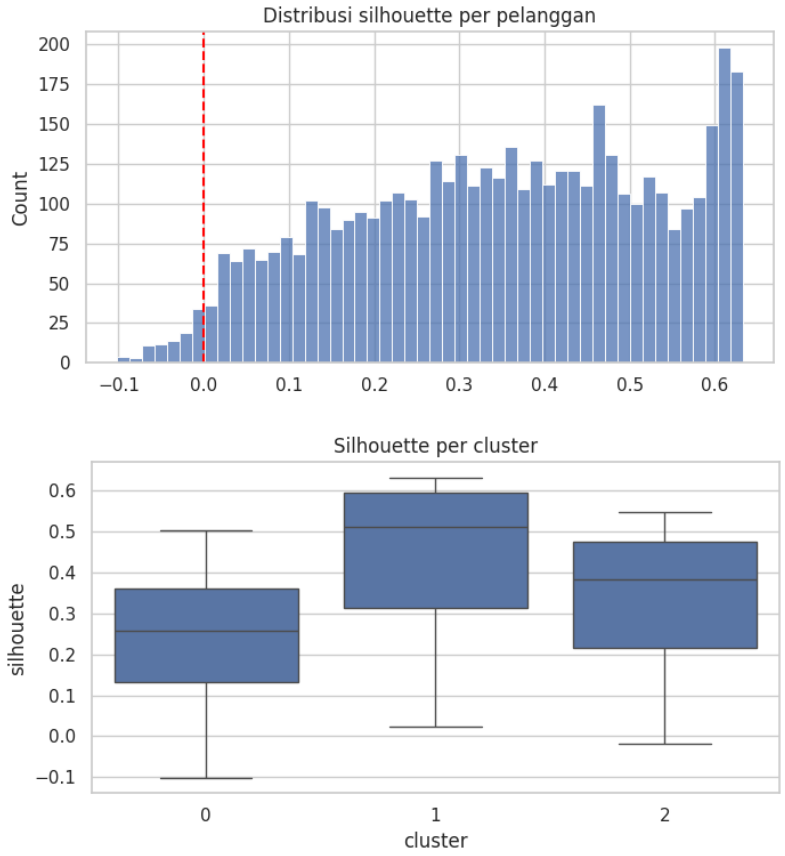
Baseline membentuk tiga segmen (Tabel 25). Cluster 2 (20,0% pelanggan; median Recency 16 hari, Frequency 13, Monetary 4.993) menyumbang 73,8% total Monetary, sedangkan cluster 1 (41,1% pelanggan; median Recency 388,5 hari dan Frequency 1) hanya menyumbang 5,6%. Silhouette data latih 0,346 dan holdout 0,356; Davies–Bouldin 1,039 dan 1,035. Selisih Silhouette hanya 0,010, sehingga struktur yang sama berlaku pada pelanggan yang tidak ikut *fit*. Nilai Calinski–Harabasz (4.118,4 pada data latih dan 1.056,0 pada holdout) tidak dibandingkan karena bergantung ukuran sampel.

Tabel 25. Ukuran dan karakteristik cluster baseline (K-Means K = 3, data latih; median dalam satuan asli)

Cluster	Jumlah	% pelanggan	Recency	Frequency	Monetary	% total Monetary
0	1.821	38,9	58	4	1.189,5	20,6
1	1.922	41,1	388,5	1	307,9	5,6
2	938	20,0	16	13	4.993,0	73,8

Sumber: Notebook, bagian E1 dan E2.

Distribusi Silhouette per pelanggan (Gambar 9) memperlihatkan 2,0% pelanggan bersilhouette negatif, yaitu berada di perbatasan antar cluster. Cluster 0 memiliki Silhouette median terendah, yang konsisten dengan posisinya sebagai kelompok antara pelanggan aktif dan tidak aktif.



Gambar 9. Distribusi Silhouette per pelanggan dan per cluster pada baseline (K = 3)
Sumber: Notebook, bagian E3.

8.2 Tabel Hasil Eksperimen Awal

Tabel 26 merangkum baseline, model kandidat, metode validasi, metrik, dan hasil. Silhouette, Davies–Bouldin, dan Calinski–Harabasz hanya sebanding antar baris R01–R05 (ruang fitur RFM yang sama); R06 dan R07 dibandingkan melalui kestabilan dan ARI.

Tabel 26. Tabel hasil eksperimen awal

Run (peran)	Model dan fitur	Parameter	Metode validasi	Silhouette	DB	CH	Silhouette holdout	Stabilitas subsampel (ARI)	CV ARI
R01 (baseline)	K-Means K = 3; RFM (3)	K = 3, k-means++, n_init = 10	Holdout 20% + 5-Fold CV + subsampel 10×80% + 10 seed	0,346	1,039	4.118,4	0,356	0,935 ± 0,037	0,946 ± 0,026
R02 (kandidat: K terpilih)	K-Means K = 4; RFM (3)	K = 4, k-means++, n_init = 10	Holdout 20% + 5-Fold CV + subsampel 10×80% + 10 seed	0,365	0,939	4.006,9	0,376	0,949 ± 0,056	0,963 ± 0,041
R03 (kandidat: metode lain)	Ward K = 4; RFM (3)	ward, K = 4	Internal (latih) + subsampel 10×80%; tanpa holdout (tak ada predict)	0,306	0,938	3.374,1	–	0,472 ± 0,084	–
R04 (kandidat: metode lain)	GMM K = 4; RFM (3)	full cov, K = 4, n_init = 3	Internal (latih) + subsampel 10×80%; tanpa holdout	0,214	1,156	2.403,2	–	0,877 ± 0,154	–

Run (peran)	Model dan fitur	Parameter	Metode validasi	Silhouette	DB	CH	Silhouette holdout	Stabilitas subsampel (ARI)	CV ARI
R05 (kandidat: metode lain)	DBSCAN eps = 0,37; RFM (3)	eps = 0,37, min_samples = 6	Internal (latih, non-noise) + subsampel 10×80%; tanpa holdout (tak ada predict)	0,277	1,013	2.255,0	–	0,980 ± 0,005	–
R06 (varian fitur)	K-Means K = 4; RFM+ (6)	K = 4, n_init = 10	Internal (ruang RFM+) + subsampel 10×80%	0,253	1,148	1.911,4	–	0,918 ± 0,138	–
R07 (reduksi dimensi)	PCA(95%) + K-Means K = 4; RFM+ (6)	5 komponen, K = 4	Internal (ruang PCA) + subsampel 10×80%	0,253	1,147	1.912,9	–	0,919 ± 0,137	–

Sumber: Notebook, bagian L1 (`tabel_hasil_uts.csv`) dan K3 (`experiment_log.csv`). Seed = 42. DB = Davies–Bouldin; CH = Calinski–Harabasz. DBSCAN dinilai pada titik non-noise. Holdout hanya dipakai pada R01 dan R02. R02 (diberi warna) adalah kandidat terbaik sementara.

Peringkat Silhouette pada ruang RFM: K-Means K = 4 (0,365), K-Means K = 3 (0,346), Ward (0,306), DBSCAN (0,277), dan GMM (0,214). Peringkat ini harus dibaca bersama kestabilan karena DBSCAN tampak sangat stabil (0,980) hanya karena membentuk dua cluster kasar.

Tabel 27. Ukuran cluster, kesepakatan partisi, dan waktu komputasi (data latih, fitur RFM)

Model	Jumlah cluster	Noise (%)	Cluster terkecil (%)	Cluster terbesar (%)	ARI vs K-Means K=4	Waktu fit (s)
K-Means K = 3 (baseline)	3	0	20,0	41,1	0,622	0,033
K-Means K = 4	4	0	19,1	34,7	1,000	0,039
Ward K = 4	4	0	14,2	33,7	0,642	0,629
GMM K = 4	4	0	16,1	37,6	0,337	0,459
DBSCAN eps = 0,37	2	2,8	27,6	72,4	0,131	0,096

Sumber: Notebook, bagian G3.

Ward dan K-Means K = 4 sepakat dengan ARI 0,642, GMM dengan 0,337, dan DBSCAN hanya 0,131. Kesepakatan yang rendah menandakan batas antar segmen kabur dan partisi peka terhadap pilihan algoritma, sejalan dengan Silhouette yang tergolong lemah.

8.3 Kestabilan dan Generalisasi

Tabel 28 menyajikan hasil 5-Fold CV untuk K = 3 dan K = 4. ARI antar-*fold* pada K = 4 mencapai 0,963 ± 0,041, lebih tinggi daripada K = 3 (0,946 ± 0,026), dan Silhouette *fold* 0,363 ± 0,012 sangat dekat dengan Silhouette data latih (0,365).

Tabel 28. 5-Fold CV pada data latih (fitur RFM)

Fold	K=3 Silhouette	K=3 DB	K=3 ARI	K=4 Silhouette	K=4 DB	K=4 ARI
Fold 1	0,356	1,021	0,970	0,371	0,934	0,992
Fold 2	0,349	1,034	0,960	0,369	0,938	0,983
Fold 3	0,320	1,097	0,960	0,345	0,946	0,988
Fold 4	0,357	1,029	0,934	0,373	0,923	0,960
Fold 5	0,341	1,040	0,906	0,358	0,948	0,893
Rata-rata	**0,345**	**1,044**	**0,946**	**0,363**	**0,938**	**0,963**
Std	0,015	0,030	0,026	0,012	0,010	0,041

Sumber: Notebook, bagian H2. ARI membandingkan partisi fold validasi dengan model data latih penuh.

Uji multi-*seed* (Tabel 29) menunjukkan bahwa K-Means dengan `k-means++` dan `n_init = 1` pada K = 4 dapat terjebak pada optimum lokal yang buruk (inertia terburuk 4.372,3 dan ARI minimum 0,499 terhadap *seed* acuan). Dengan `n_init = 10`, hasil menjadi hampir identik antar *seed* (inertia 3.933,452 ± 0,016; ARI rata-rata 0,999). Karena itu `k-means++` dengan `n_init > 1` dipakai pada seluruh model K-Means.

Tabel 29. Kestabilan terhadap inisialisasi (10 seed, data latih)

Konfigurasi	Inertia (rata-rata)	Inertia (std)	Inertia terburuk	ARI vs seed 0 (rata-rata)	ARI vs seed 0 (min)
K = 3 | random, n_init = 1	5.087,341	0,498	5.087,924	0,951	0,894
K = 3 | k-means++, n_init = 1	5.087,273	0,554	5.088,016	0,941	0,894
K = 3 | k-means++, n_init = 10	5.086,756	0,044	5.086,803	0,971	0,931
K = 4 | random, n_init = 1	3.935,069	1,049	3.935,886	0,930	0,906
K = 4 | k-means++, n_init = 1	3.978,312	131,342	4.372,324	0,900	0,499
K = 4 | k-means++, n_init = 10	3.933,452	0,016	3.933,470	0,999	0,998

Sumber: Notebook, bagian H3.

Konfirmasi pada holdout (K = 4): Silhouette 0,365 pada data latih dan 0,376 pada holdout, Davies–Bouldin 0,939 dan 0,930. Selisihnya kecil dan holdout justru sedikit lebih baik, sehingga tidak ada indikasi *overfitting*. Komposisi cluster holdout berbeda paling banyak 1,5 poin persentase dari data latih (segmen 0: 19,1% vs 18,8%; segmen 1: 34,7% vs 36,0%; segmen 2: 25,2% vs 23,7%; segmen 3: 21,1% vs 21,5%).

8.4 Dampak Fitur Tambahan dan Reduksi Dimensi

Varian RFM+. Penambahan UniqueProducts, AvgBasketValue, dan ReturnRate menghasilkan partisi yang cukup berbeda dari RFM (ARI 0,369) dengan kestabilan subsampel 0,918 ± 0,138 (RFM: 0,949 ± 0,056). Silhouette RFM+ (0,253) tidak boleh dibandingkan langsung dengan RFM (0,365) karena ruang fiturnya berbeda. Temuan utama RFM+ adalah munculnya segmen mikro berisi 53 pelanggan (1,1%) dengan

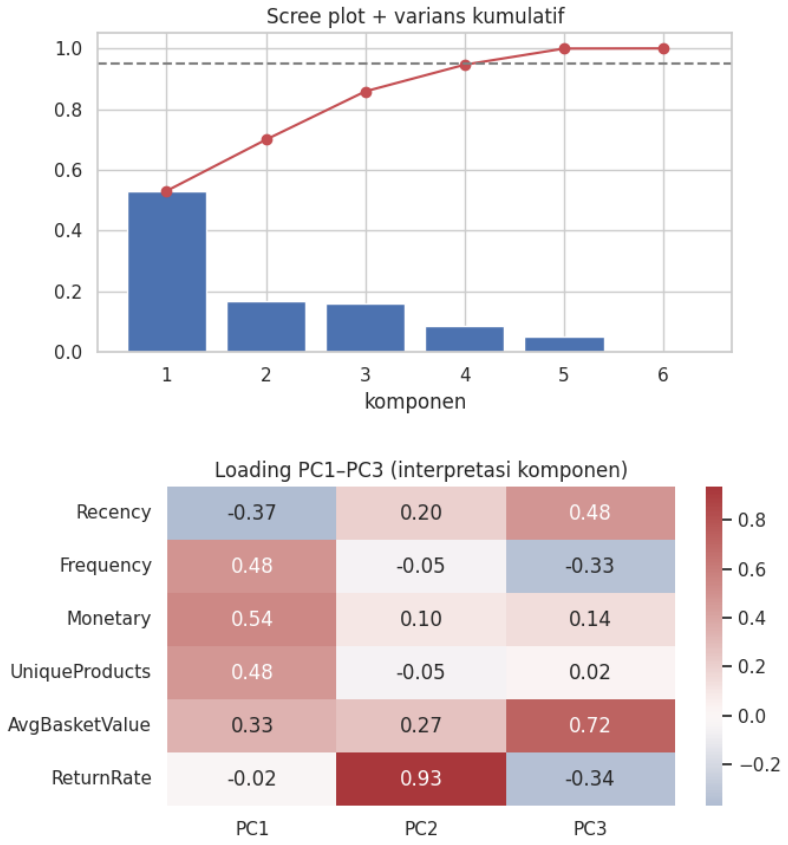
median ReturnRate 0,50, yang tidak terlihat pada RFM (Tabel 30). Segmen ini berpotensi menjadi kelompok berisiko/biaya retur tinggi dan layak ditinjau pada tahap berikutnya.

Tabel 30. Profil cluster K-Means K = 4 pada fitur RFM+ (median, satuan asli)

Cluster	Jumlah	% pel.	% total Monetary	Recency	Freq.	Monetary	Unique Products	AvgBasket Value	Return Rate
0	2.050	43,8	18,7	110	3	958,7	50	327,3	0,000
1	1.157	24,7	77,4	18	12	4.234,5	162	354,5	0,009
2	53	1,1	1,4	301	2	385,2	11	194,4	0,498
3	1.421	30,4	2,6	376	1	226,4	13	157,9	0,000

Sumber: Notebook, bagian G4. Cluster 2 (diberi warna) adalah segmen mikro retur tinggi.

PCA. Pada RFM+ (enam fitur), PC1 menjelaskan 53,1% varians dan empat komponen pertama 94,6% (90% tercapai dengan 4 komponen, 95% dengan 5 komponen; Gambar 10). PC6 hanya menjelaskan 0,05% varians, yang mengindikasikan kolinearitas (AvgBasketValue = Monetary ÷ Frequency sehingga log-nya hampir sama dengan selisih log Monetary dan log Frequency). Pipeline PCA(95%) + K-Means memakai lima komponen dan menghasilkan partisi identik dengan RFM+ tanpa PCA (ARI 1,000). Berdasarkan uji tugas hilir (Tabel 31), tiga komponen merupakan jumlah minimum yang mempertahankan partisi (ARI ≥ 0,90 terhadap tanpa PCA; 0,940) dengan kestabilan yang lebih baik (0,961 ± 0,025). Meskipun demikian, PCA menurunkan interpretabilitas karena komponen merupakan campuran fitur; dengan hanya enam fitur, PCA di sini bertujuan menguji redundansi, bukan mengatasi *curse of dimensionality*.



Gambar 10. Scree plot dengan varians kumulatif dan loading PC1–PC3 pada fitur RFM+

Sumber: Notebook, bagian I1.

Tabel 31. Pemilihan jumlah komponen PCA melalui uji tugas hilir (RFM+, K = 4)

Jumlah komponen	Varians kumulatif	ARI vs tanpa PCA	Kestabilan subsampel (ARI)
2	0,700	0,775	0,743 ± 0,181
3	0,859	0,940	0,961 ± 0,025
4	0,946	0,959	0,968 ± 0,022
5	0,999	1,000	0,919 ± 0,137
6 (tanpa PCA)	1,000	1,000	0,918 ± 0,138

Sumber: Notebook, bagian I4. Silhouette di ruang PCA tidak sebanding antar baris sehingga tidak ditampilkan. Visualisasi PCA, t-SNE, dan UMAP serta galat rekonstruksi PCA ada pada Lampiran B.

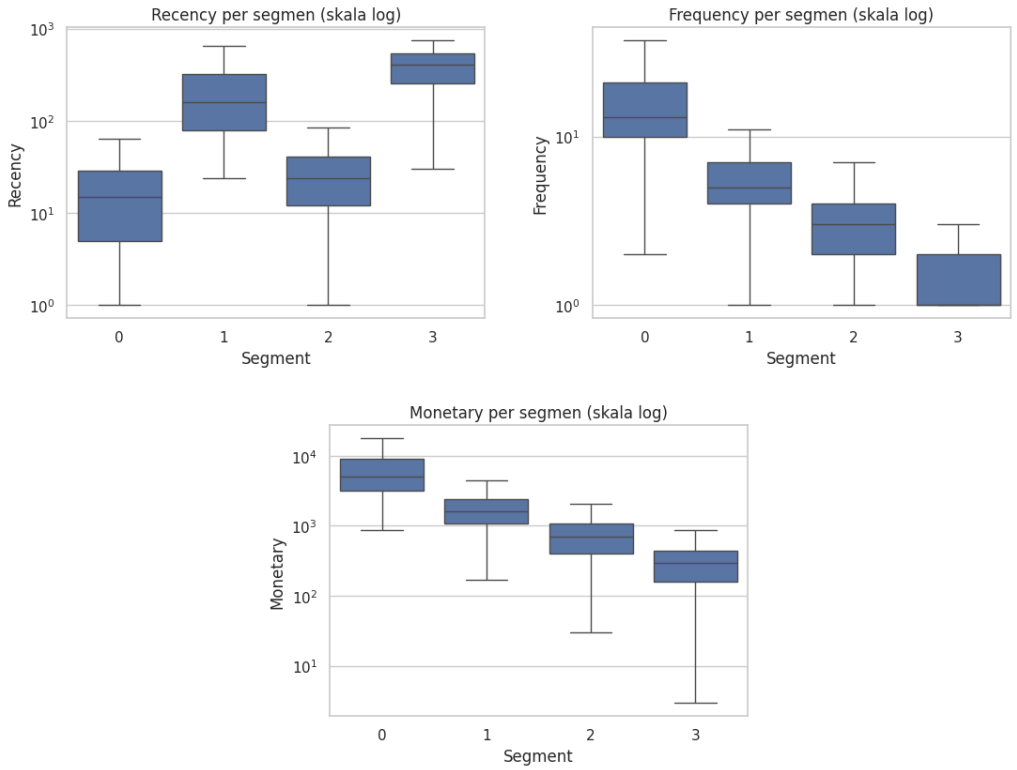
8.5 Segmentasi Kandidat dan Profil Segmen

Pipeline kandidat (K-Means K = 4, `n_init = 20`, di-*fit* hanya pada data latih) diterapkan pada seluruh 5.852 pelanggan. Nomor segmen diurutkan menurut median Monetary menurun (segmen 0 = nilai tertinggi). Tabel 32 menyajikan profil dalam satuan asli, dan Gambar 11 serta Gambar 12 memperlihatkan perbedaan fitur antar segmen.

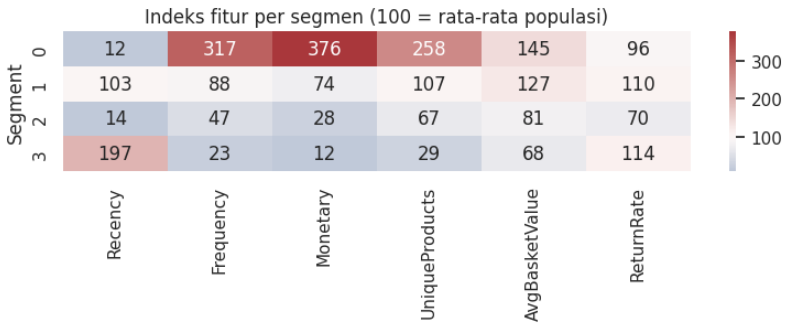
Tabel 32. Profil segmen kandidat (median dalam satuan asli) dan nama usulan

Segmen	Jumlah	% pel.	% total Monetary	Recency	Freq.	Monetary	Nama usulan
0	1.112	19,0	71,5	15	13	5.088,1	Champions / Loyal High-Value
1	1.455	24,9	18,5	157	5	1.594,7	At Risk (dulu aktif)
2	1.240	21,2	5,9	24	3	700,5	New / Recent Low-Frequency
3	2.045	34,9	4,1	401	1	292,0	Dormant / Lost

Sumber: Notebook, bagian J1. Nama diberikan oleh aturan berbasis z-skor median log terhadap populasi; label "New" bersifat heuristik, sebab segmen 2 aktif baru-baru ini dengan median 3 faktur. Nama dan tindakan adalah usulan analis dan belum divalidasi pemangku kepentingan.



Gambar 11. Sebaran Recency, Frequency, dan Monetary per segmen (skala log)
Sumber: Notebook, bagian J1.



Gambar 12. Indeks fitur per segmen terhadap rata-rata populasi (100 = sama dengan populasi)

Sumber: Notebook, bagian J1b.

Segmen 0 (19,0% pelanggan) menyumbang 71,5% total Monetary dengan Frequency rata-rata 316,9% dari rata-rata populasi, sedangkan segmen 3 (34,9% pelanggan) hanya menyumbang 4,1% dengan Recency 197% dari rata-rata. Fitur di luar RFM yang tidak dipakai saat *clustering* juga membedakan segmen: UniqueProducts memiliki $\eta^2 = 0{,}45$ (efek besar), sedangkan AvgBasketValue ($\eta^2 = 0{,}13$) berefek sedang mendekati besar dan ReturnRate ($\eta^2 = 0{,}002$) praktis tidak membedakan segmen. Hal ini menjadi bukti tambahan bahwa segmen bermakna di luar fitur pembentuknya, kecuali pada perilaku retur (Tabel 33).

Tabel 33. Fitur yang paling membedakan segmen (η^2, log1p kecuali ReturnRate)

Fitur	η^2	Dipakai untuk clustering	Kategori efek (Cohen)
Frequency	0,749	Ya	Besar
Recency	0,720	Ya	Besar
Monetary	0,691	Ya	Besar
UniqueProducts	0,447	Tidak	Besar
AvgBasketValue	0,132	Tidak	Sedang
ReturnRate	0,002	Tidak	Kecil

Sumber: Notebook, bagian J1b-3.

Tabel 34. Tindakan bisnis yang disarankan per segmen

Segmen	Nama usulan	Tindakan yang disarankan
0	Champions / Loyal High-Value	Program loyalitas/VIP dan akses awal produk; hindari diskon berlebihan.
1	At Risk (dulu aktif)	Kampanye *win-back* dengan penawaran personal sebelum pelanggan hilang.
2	New / Recent Low-Frequency	*Onboarding*, voucher pembelian kedua, dan rekomendasi produk.
3	Dormant / Lost	Reaktivasi berbiaya rendah (email) dan evaluasi apakah layak dikejar.

Sumber: Notebook, bagian J1.

8.6 Evaluasi terhadap Kriteria Keberhasilan

Tabel 35. Evaluasi K-Means K = 4 terhadap kriteria keberhasilan

Kriteria	Ambang	Hasil	Status
Stabil	ARI ≥ 0,8	ARI antar-fold 0,963 ± 0,041; kestabilan subsampel 0,949 ± 0,056	Terpenuhi
Bukan artefak	Silhouette ≥ 0,26	Silhouette latih 0,365 dan holdout 0,376	Terpenuhi
Tanpa segmen mikro	Cluster terkecil ≥ 1%	Cluster terkecil 19,1% (data latih)	Terpenuhi
Dapat ditafsirkan bisnis	Validasi pemangku kepentingan	Nama dan tindakan masih usulan analis	Belum (dijadwalkan)

Sumber: Notebook, bagian L2.

8.7 Analisis Hasil, Keterbatasan, dan Hal yang Perlu Diperbaiki

1. **Perbedaan hasil antar model.** K-Means K = 4 unggul pada Silhouette (0,365) dan stabil (0,949), sedangkan Ward kurang stabil (ARI 0,472; partisinya peka terhadap sampel dan tidak memiliki fungsi `predict` untuk pelanggan baru), GMM memiliki kestabilan rendah dengan variasi besar (0,877 ± 0,154) dan Silhouette terendah (0,214), dan DBSCAN hanya menghasilkan dua cluster kasar sehingga lebih cocok sebagai pendeteksi pelanggan ekstrem. Peralihan dari K = 3 ke K = 4 mengubah Silhouette dari 0,346 menjadi 0,365 dan Davies–Bouldin dari 1,039 menjadi 0,939; ini perbedaan granularitas, bukan benar atau salah.
2. **Padanan "kelas yang sering salah diprediksi".** Karena tidak ada label, kesalahan diwakili oleh pelanggan di perbatasan segmen: 1,6% pelanggan bersilhouette negatif pada K = 4 (2,0% pada baseline). Kemungkinan penyebabnya adalah perilaku

pelanggan yang membentuk kontinum aktivitas dan korelasi tinggi antarfitur RFM. Analisis pelanggan perbatasan secara mendalam termasuk pekerjaan tahap UAS.

3. **Indikasi *overfitting* atau *underfitting*.** Tidak ada indikasi *overfitting*: Silhouette data latih dan holdout hampir sama (0,365 dan 0,376) dan ARI antar-*fold* tinggi. Istilah *underfitting* tidak sepenuhnya relevan untuk *clustering*, tetapi Silhouette yang tergolong lemah menunjukkan bahwa struktur data bersifat kontinum sehingga segmen yang ditemukan lebih bersifat "tingkat aktivitas" daripada gumpalan terpisah tegas.
4. **Keterbatasan.** (1) Silhouette tergolong lemah. (2) Hanya satu periode data, 91,9% baris dari United Kingdom, dan 22,8% baris tanpa `CustomerID` tidak tercakup. (3) Tanggal acuan Recency bersifat global. (4) Tidak ada *ground truth*. (5) Varian RFM+ memuat fitur hampir kolinear dan ReturnRate yang tetap miring. (6) Nama dan tindakan segmen belum divalidasi pemangku kepentingan. Hal-hal yang perlu diperbaiki dirumuskan sebagai rencana pada Bab 10.

9. Teknologi yang Digunakan

Tabel 36. Teknologi, pustaka, dan lingkungan pengembangan

Kategori	Teknologi	Versi / spesifikasi
Bahasa pemrograman	Python	3.13.16 (Linux 6.6.159+, glibc 2.39)
Komputasi dan ML	NumPy; pandas; scikit-learn; SciPy	numpy 2.4.6; pandas 2.2.3; scikit-learn 1.6.1; scipy 1.16.3
Visualisasi	Matplotlib; seaborn	matplotlib 3.10.0; seaborn 0.13.2
Utilitas	joblib; openpyxl; umap-learn; kagglehub	joblib 1.6.0; openpyxl 3.1.5; umap-learn 0.5.12; kagglehub 1.0.3
Lingkungan pengembangan	Google Colab (Jupyter Notebook)	Akselerator GPU T4 tercatat pada metadata notebook, tetapi seluruh algoritma scikit-learn berjalan di CPU sehingga GPU tidak dibutuhkan
Framework aplikasi dan hosting	Tidak digunakan	Tidak ada deployment pada Milestone 1

Sumber: Notebook, bagian K1b (versi pustaka yang benar-benar dipakai pada run tersimpan). Pustaka dirujuk pada Daftar Pustaka.

10. Dokumentasi, Reprodusibilitas, dan Rencana Pasca-UTS

10.1 Dokumentasi dan Reprodusibilitas

Eksperimen yang tidak dapat dijalankan ulang dengan hasil yang sama belum dapat diklaim sebagai temuan. Notebook karenanya menutup tiga pilar reprodusibilitas (seed, lingkungan, dan versi data) serta menambahkan uji konsistensi, log eksperimen, dan *model card* (Mitchell et al., 2019).

Tabel 37. Dokumentasi dan reprodusibilitas eksperimen

Aspek	Implementasi	Bukti
Random seed	`RANDOM_STATE = 42` dan `np.random.seed(42)`; `random_state` eksplisit pada seluruh estimator utama	Checklist K5: lulus
Lingkungan	Versi pustaka dicatat otomatis	`outputs/requirements.txt`
Versi data	Sidik jari SHA-256 berkas dan isi *DataFrame*; tag data 4d3b2f7f; rentang waktu dan jumlah baris	`outputs/data_manifest.json`
Konsistensi antar-*run*	Pipeline dijalankan ulang dengan *seed* sama: label seluruh pelanggan identik (ARI 1,000), pusat cluster identik (selisih maks 0), pembagian 4.681/1.171 identik, Silhouette 0,3650 vs 0,3650	Uji K2: lulus
Log eksperimen	Tujuh *run* (R01–R07) dengan model, fitur, parameter, *seed*, dan metrik	`outputs/experiment_log.csv`
Model card	Dihasilkan otomatis dari hasil *run*	`outputs/MODEL_CARD.md`
Konsistensi laporan notebook	Sepuluh pemeriksaan otomatis lintas tabel, log, manifest, dan *model card*	Uji L4-1: lulus

Sumber: Notebook, bagian K1–K5 dan L4. Satu butir checklist berupa uji manual (Restart session and run all) harus dicentang setelah dijalankan pada mesin bersih.

Berkas keluaran lain yang dihasilkan notebook pada folder `outputs/` adalah `customer_segments.csv`, `segment_profile.csv`, `segment_profile_mean.csv`, `segment_feature_eta2.csv`, `model_comparison.csv`, `kmeans_k_sweep.csv`, `tabel_hasil_uts.csv`,

`report_numbers.csv`, `rencana_pasca_uts.md`, dan `segmentation_pipeline.joblib`.

10.2 Cara Menjalankan Ulang

1. Buka notebook pada Google Colab, lalu pilih *Runtime* → *Run all*.
2. Data dicari otomatis: berkas lokal (`/content`, direktori kerja) terlebih dahulu, kemudian unduhan `kagglehub`. Pemuatan berkas Excel memerlukan sekitar 1,5–2 menit.
3. Bila unduhan gagal, unduh `online_retail_II.xlsx` dari UCI atau Kaggle (tautan pada Bagian B), unggah ke `/content`, atau isi `CFG["LOCAL_PATH"]`.
4. Keluaran tersimpan pada folder `outputs/`.
5. Uji reprodusibilitas dengan *Runtime* → *Restart session and run all*; uji K2 harus tetap lulus.

10.3 Rencana Pengembangan Pasca-UTS

Rencana disusun berdasarkan temuan nyata pada Milestone 1, bukan daftar umum. Urutan mengikuti ketergantungan antar tahap (fitur, tuning, validasi, analisis kesalahan, lalu keputusan final), sedangkan jadwal mengikuti kalender akademik. Tuning menyeluruh, *error analysis* lengkap, dan pemilihan model final termasuk Milestone UAS.

Tabel 38. Rencana pasca-UTS menuju final project UAS

Tahap dan pekerjaan	Dipicu oleh temuan	Keluaran	Kriteria selesai
1. Perluasan dan seleksi fitur. Bandingkan himpunan fitur (RFM, RFM tanpa salah satu fitur redundan, RFM+, serta tambahan kategori produk, musiman, dan *tenure*) lewat ARI antar partisi, kestabilan, dan profil bisnis.	Spearman Frequency–Monetary 0,86; RFM vs RFM+ hanya sepakat ARI 0,369 dan Silhouette lintas ruang tidak sebanding	Tabel perbandingan fitur dan keputusan fitur	Himpunan fitur terpilih dengan kestabilan ARI ≥ 0,8 dan profil dapat ditafsirkan

Tahap dan pekerjaan	Dipicu oleh temuan	Keluaran	Kriteria selesai
2. Tuning terstruktur kandidat. Grid K (3–8) × inisialisasi; `covariance_type` GMM; `eps`/`min_samples` DBSCAN lewat k-distance; *linkage* Ward; seleksi berbasis kestabilan dan metrik internal pada ruang yang sama.	Kestabilan subsampel Ward 0,472; std kestabilan GMM 0,154; DBSCAN hanya 2 cluster pada eps = 0,37	Tabel hasil tuning dan log eksperimen	Konfigurasi terbaik tiap metode dengan bukti kestabilan
3. Validasi robustness dan out-of-time. Bentuk fitur per paruh periode, *fit* pada paruh awal, uji pada paruh akhir; ukur pergeseran komposisi segmen dan ARI.	Data hanya satu periode (2009-12 s.d. 2011-12); Silhouette tergolong lemah	Tabel kestabilan temporal	Komposisi segmen dan ARI antar periode terdokumentasi
4. Analisis kesalahan dan perbatasan segmen. Telaah pelanggan bersilhouette < 0, probabilitas posterior GMM untuk pelanggan perbatasan, dan segmen mikro retur tinggi.	1,6% pelanggan bersilhouette negatif; segmen K-Means terkecil 19,1%; cluster RFM+ terkecil 1,1% dengan median ReturnRate 0,50	Daftar kasus batas dan penjelasan penyebab	Sebab utama kesalahan batas teridentifikasi
5. Validasi bisnis dan sensitivitas K. Tinjau nama dan tindakan segmen bersama pemangku kepentingan; bandingkan profil K = 3, 4, dan 5.	Nama dan tindakan masih usulan analis; K dipilih terutama dari metrik	Tabel segmen dan keputusan bisnis	Segmen dapat dijelaskan dan ditindaklanjuti

Tahap dan pekerjaan	Dipicu oleh temuan	Keluaran	Kriteria selesai
6. Pemilihan model final dan dokumentasi. Pilih model akhir dari tabel tuning; perbarui *model card*; uji *restart and run all*; susun laporan UAS, presentasi, dan persiapan *defense*.	Model final belum boleh diputuskan pada UTS karena bukti belum cukup	Model final, laporan, dan presentasi	Hasil dapat dijalankan ulang dengan *seed* sama (K2, K5)

Sumber: Notebook, bagian L3 (`outputs/rencana_pasca_uts.md`).

10.4 Keterlacakan Angka Laporan ke Notebook

Seluruh angka utama dalam laporan dapat ditelusuri ke notebook. Tabel 39 memuat angka rujukan yang dihasilkan notebook (`outputs/report_numbers.csv`) beserta lokasi bagiannya.

Tabel 39. Angka rujukan laporan dan lokasinya pada notebook

Angka	Nilai	Lokasi di notebook
Baris data mentah	1.067.371	B1
Fitur mentah	8	B1
Rentang waktu	2009-12-01 s.d. 2011-12-09	B1
Pelanggan di data mentah	5.942	B1 / C2b
Baris penjualan sah	776.579	C1
Pelanggan dianalisis (unit analisis)	5.852	C2
Train / holdout	4.681 / 1.171	C3
K baseline	3	D
K terpilih (K*)	4	G1
DBSCAN eps / min_samples	0,37 / 6	G2
Silhouette baseline (latih)	0,346	G3 / L1
Silhouette K* (latih)	0,365	G3 / L1
Davies–Bouldin K* (latih)	0,939	G3 / L1
Silhouette K* (holdout)	0,376	H4 / L1
ARI antar-fold K* (5-Fold CV)	0,963 ± 0,041	H2 / H5
Kestabilan subsampel K*	0,949 ± 0,056	G3 / L1

Angka	Nilai	Lokasi di notebook
Komponen PCA untuk 90% / 95% varians (RFM+)	4 / 5	I1
Seed	42	CFG
Tag versi data (8 karakter awal SHA-256)	4d3b2f7f	K1c

Sumber: Notebook, bagian L4-2.

11. Kesimpulan

Milestone 1 menunjukkan bahwa masalah segmentasi pelanggan dapat dirumuskan secara jelas, dataset *Online Retail II* sesuai dengan tujuan, dan proses pengolahan data dapat dijelaskan serta bebas kebocoran. Dari 1.067.371 baris transaksi mentah diperoleh 5.852 pelanggan yang dianalisis, dengan nilai pelanggan yang sangat timpang (20% pelanggan teratas menyumbang 77,2% total Monetary).

Baseline K-Means (K = 3) menghasilkan Silhouette 0,346 (latih) dan 0,356 (holdout). Seleksi jumlah cluster dengan konsensus peringkat pada K ∈ [3, 8] menghasilkan K-Means K = 4 sebagai kandidat terbaik sementara (Silhouette 0,365 latih dan 0,376 holdout; Davies–Bouldin 0,939; ARI antar-fold 0,963 ± 0,041). Kandidat ini mengungguli Ward, GMM, dan DBSCAN pada kombinasi Silhouette dan kestabilan, serta memenuhi tiga dari empat kriteria keberhasilan; kriteria kebermaknaan bisnis menunggu validasi pemangku kepentingan. Empat segmen yang terbentuk, dengan segmen bernilai tertinggi (19,0% pelanggan) menyumbang 71,5% total Monetary, berpotensi menjadi dasar perbedaan strategi promosi, retensi, dan layanan.

Keterbatasan utama adalah struktur segmen yang tergolong lemah (kontinum), satu periode data, dominasi pasar United Kingdom, dan tidak adanya *ground truth*. Karena itu model final belum diputuskan pada tahap ini. Enam tahap pasca-UTS (perluasan fitur, tuning terstruktur, validasi out-of-time, analisis kesalahan, validasi bisnis, dan pemilihan model final) disusun untuk menjawab keterbatasan tersebut menuju final project UAS.

12. Lampiran

Lampiran A. Cuplikan Kode Penting

Cuplikan berikut diringkas dari notebook (komentar dan baris pencatatan dihilangkan); versi lengkap tersedia pada notebook yang dikumpulkan.

A.1 Pembersihan transaksi (bagian C1)

```
NON_PRODUCT = {"POST", "DOT", "M", "C2", "C3", "D", "S",
"BANK CHARGES",
               "ADJUST", "ADJUST2", "AMAZONFEE", "CRUK",
"B",
               "TEST001", "TEST002", "PADS"}

def clean_transactions(df):
    d = df.drop_duplicates().copy()
    d = d.dropna(subset=["CustomerID", "InvoiceDate",
"Quantity", "Price"])
    d["CustomerID"] = d["CustomerID"].astype("int64")
    d = d[~d["StockCode"].str.upper().isin(NON_PRODUCT)]
    is_cancel =
d["Invoice"].str.upper().str.startswith("C")
    returns = d[is_cancel | (d["Quantity"] < 0)]
    returns = returns[returns["Price"] > 0].copy()
    sales = d[(~is_cancel) & (d["Quantity"] > 0) &
(d["Price"] > 0)].copy()
    sales["TotalPrice"] = sales["Quantity"] *
sales["Price"]
    returns["ReturnValue"] = returns["Quantity"].abs() *
returns["Price"]
    return sales, returns
```

A.2 Fitur level pelanggan (bagian C2)

```
SNAPSHOT = sales["InvoiceDate"].max() +
pd.Timedelta(days=1)

def build_customer_features(sales, returns, snapshot):
    g = sales.groupby("CustomerID")
    cust = pd.DataFrame({
        "Recency":   (snapshot -
g["InvoiceDate"].max()).dt.days,
        "Frequency": g["Invoice"].nunique(),
        "Monetary":  g["TotalPrice"].sum(),
        "UniqueProducts": g["StockCode"].nunique(),
    })
    cust["AvgBasketValue"] = cust["Monetary"] /
cust["Frequency"]
    ret_val =
returns.groupby("CustomerID")["ReturnValue"].sum()
    cust["ReturnRate"] =
(ret_val.reindex(cust.index).fillna(0)
                          / cust["Monetary"]).clip(0, 1)
    return cust
```

A.3 Preprocessor dalam Pipeline dan pembagian data (bagian C3)

```
def make_preprocessor(cols):
    log_cols = [c for c in cols if c != "ReturnRate"]
    ct = ColumnTransformer(
        [("log", FunctionTransformer(np.log1p,
validate=False,

feature_names_out="one-to-one"), log_cols)],
        remainder="passthrough",
verbose_feature_names_out=False)
    return Pipeline([("log", ct), ("scaler",
StandardScaler())])

train_idx, hold_idx = train_test_split(cust.index,
test_size=0.20,
                                       random_state=42)
prep_rfm = make_preprocessor(RFM).fit(cust_tr[RFM])   #
fit hanya pada train
X_tr = prep_rfm.transform(cust_tr[RFM])
X_ho = prep_rfm.transform(cust_ho[RFM])               #
holdout: hanya transform
```

A.4 Baseline dan sweep K (bagian D dan G1)

```
base_km = KMeans(n_clusters=3, init="k-means++",
n_init=10,
                 random_state=42).fit(X_tr)
lab_base_ho = base_km.predict(X_ho)       # holdout hanya
predict

for k in range(2, 11):
    km = KMeans(n_clusters=k, init="k-means++",
n_init=10,
                random_state=42).fit(X_tr)
    m = cluster_metrics(X_tr, km.labels_)  # silhouette,
DB, CH
```

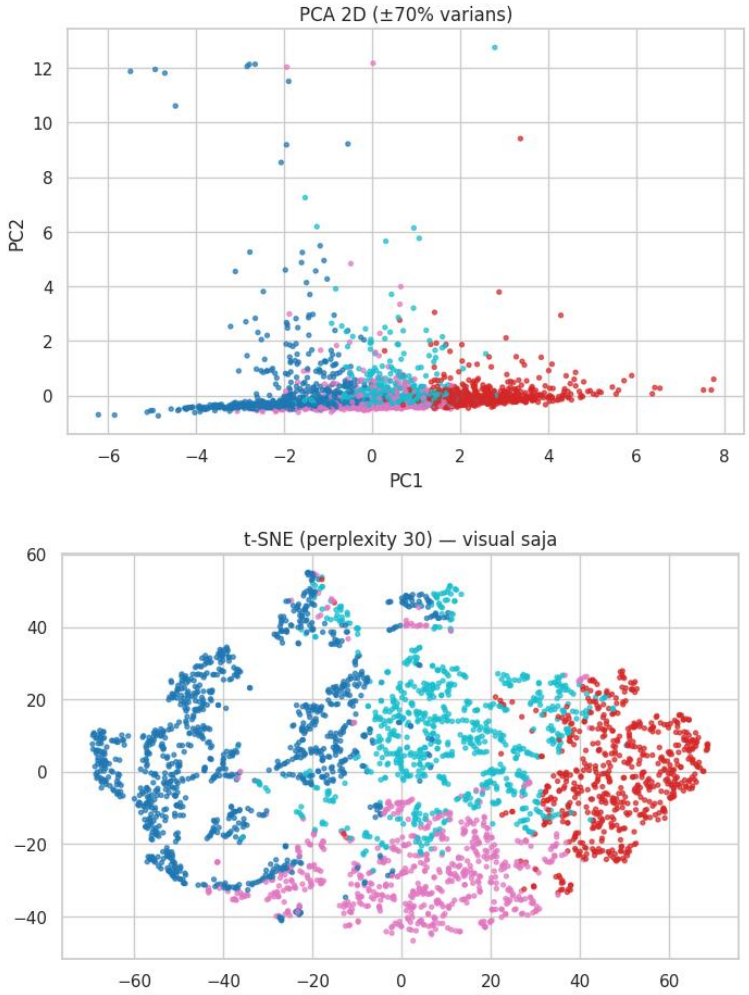
A.5 Kestabilan subsampel (bagian G3)

```
def subsample_stability(factory, X, n_rep, frac, seed):
    rng = np.random.default_rng(seed); n = len(X); m =
int(frac * n)
    scores = []
    for _ in range(n_rep):
        i1 = rng.choice(n, m, replace=False)
        i2 = rng.choice(n, m, replace=False)
        l1 = factory().fit_predict(X[i1]); l2 =
factory().fit_predict(X[i2])
        f1, f2 = np.full(n, -9), np.full(n, -9); f1[i1],
f2[i2] = l1, l2
```

```
        both = np.intersect1d(i1, i2)
        scores.append(adjusted_rand_score(f1[both],
f2[both]))
    return float(np.mean(scores)), float(np.std(scores))
```

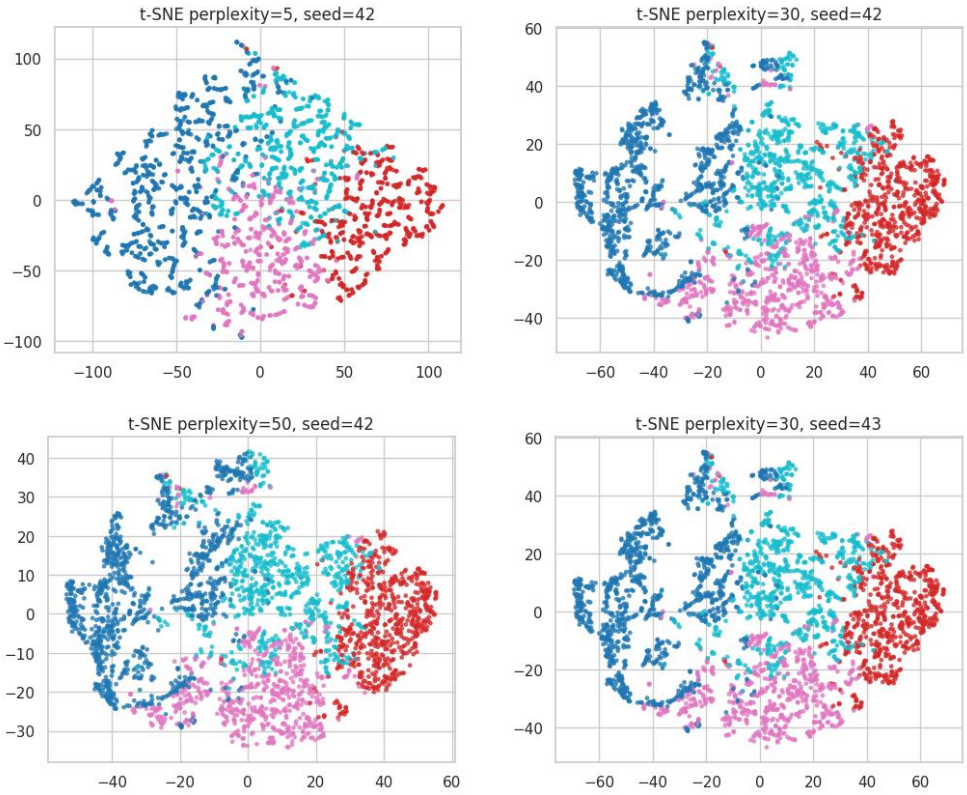
Lampiran B. Grafik Tambahan

Proyeksi dua dimensi pada lampiran ini hanya untuk visualisasi, bukan sebagai fitur maupun bukti jumlah cluster; ukuran dan jarak cluster pada t-SNE dan UMAP tidak bermakna, dan hasilnya berubah menurut *perplexity* dan *seed* (van der Maaten & Hinton, 2008; McInnes et al., 2018). Kualitas lokal proyeksi diukur dengan *trustworthiness@10* (Tabel 42).



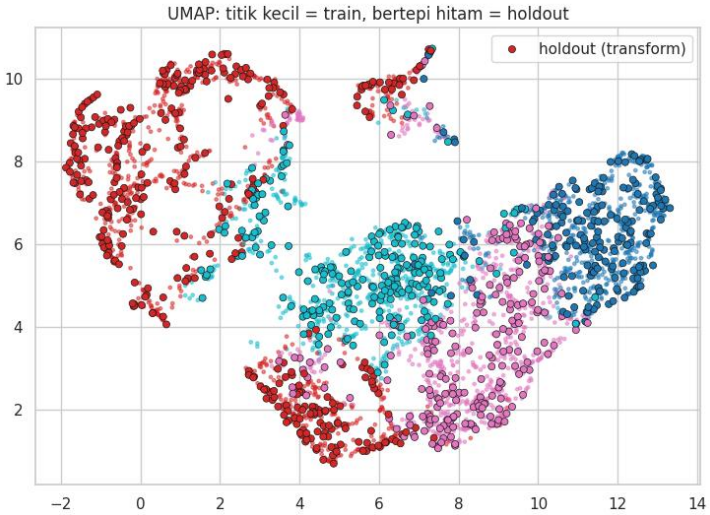
Gambar 13. Proyeksi 2D PCA (± 70% varians) dan t-SNE (perplexity 30) pada fitur RFM+; warna = cluster K-Means K = 4

Sumber: Notebook, bagian I2.



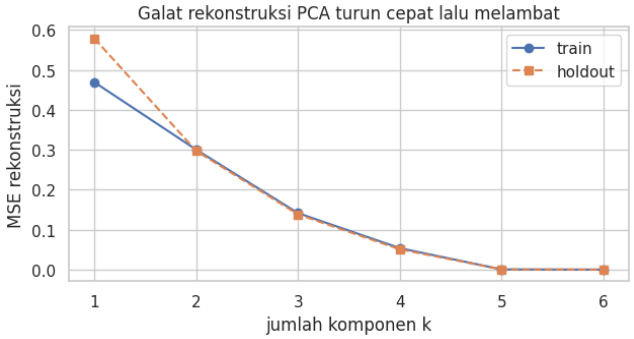
Gambar 14. Sensitivitas t-SNE terhadap perplexity (5, 30, 50) dan seed (42, 43)

Sumber: Notebook, bagian I5.



Gambar 15. Proyeksi UMAP: titik kecil = data latih, titik bertepi hitam = holdout (transform)

Sumber: Notebook, bagian I6.



Gambar 16. Galat rekonstruksi PCA terhadap jumlah komponen

Sumber: Notebook, bagian I3.

Lampiran C. Tabel Tambahan

Tabel 40. Profil rata-rata segmen dalam satuan asli (K-Means K = 4)

Segmen	Jumlah	Recency	Frequency	Monetary	Unique Products	AvgBasket Value	Return Rate
0	1.112	24,6	19,8	10.972,7	211,9	557,0	0,022
1	1.455	206,3	5,5	2.171,9	87,9	488,4	0,026
2	1.240	29,0	2,9	809,0	55,5	312,6	0,017
3	2.045	395,1	1,4	344,1	23,8	260,0	0,027

Sumber: Notebook, bagian J1b-1.

Tabel 41. Galat rekonstruksi PCA pada RFM+ terstandarisasi

k	Varians kumulatif	MSE latih	MSE holdout	1 − varians kumulatif
1	0,531	0,469	0,579	0,469
2	0,700	0,300	0,297	0,300
3	0,859	0,141	0,138	0,141
4	0,946	0,054	0,051	0,054
5	0,999	0,001	0,001	0,001
6	1,000	0,000	0,000	0,000

Sumber: Notebook, bagian I3. Karena tiap fitur berskala varians ≈ 1, MSE rekonstruksi ≈ 1 − varians kumulatif (selisih maksimum 0,0000). Dengan k = 2, 30% informasi dibuang.

Tabel 42. Trustworthiness@10 proyeksi dua dimensi

Proyeksi	Trustworthiness@10
PCA 2D	0,872
t-SNE (perplexity 5, seed 42)	0,990
t-SNE (perplexity 30, seed 42)	0,994
t-SNE (perplexity 50, seed 42)	0,993
t-SNE (perplexity 30, seed 43)	0,994
UMAP (n_neighbors 15, min_dist 0,1)	0,979

Sumber: Notebook, bagian I5 dan I6. Trustworthiness hanya menilai kualitas lokal.

DAFTAR PUSTAKA

adilhabib. (t.t.). *Online retail data clustering* [Dataset]. Kaggle. https://www.kaggle.com/datasets/adilhabib/online-retail-data-clustering

Arthur, D., & Vassilvitskii, S. (2007). k-means++: The advantages of careful seeding. Dalam *Proceedings of the 18th Annual ACM-SIAM Symposium on Discrete Algorithms (SODA '07)* (hlm. 1027–1035). Society for Industrial and Applied Mathematics.

Caliński, T., & Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics, 3*(1), 1–27. https://doi.org/10.1080/03610927408827101

Chen, D. (2012). *Online Retail II* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5CG6D

Chen, D., Sain, S. L., & Guo, K. (2012). Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining. *Journal of Database Marketing & Customer Strategy Management, 19*(3), 197–208. https://doi.org/10.1057/dbm.2012.17

Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (edisi ke-2). Lawrence Erlbaum Associates.

Davies, D. L., & Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence, PAMI-1*(2), 224–227. https://doi.org/10.1109/TPAMI.1979.4766909

Dempster, A. P., Laird, N. M., & Rubin, D. B. (1977). Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society: Series B, 39*(1), 1–38.

Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. Dalam *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD-96)* (hlm. 226–231). AAAI Press.

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., … Oliphant, T. E. (2020). Array programming with NumPy. *Nature, 585*, 357–362. https://doi.org/10.1038/s41586-020-2649-2

Hubert, L., & Arabie, P. (1985). Comparing partitions. *Journal of Classification, 2*(1), 193–218. https://doi.org/10.1007/BF01908075

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering, 9*(3), 90–95. https://doi.org/10.1109/MCSE.2007.55

Jolliffe, I. T., & Cadima, J. (2016). Principal component analysis: A review and recent developments. *Philosophical Transactions of the Royal Society A, 374*(2065), 20150202. https://doi.org/10.1098/rsta.2015.0202

Kaufman, L., & Rousseeuw, P. J. (1990). *Finding groups in data: An introduction to cluster analysis*. John Wiley & Sons.

McInnes, L., Healy, J., & Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for dimension reduction. *arXiv*. https://doi.org/10.48550/arXiv.1802.03426

McKinney, W. (2010). Data structures for statistical computing in Python. Dalam *Proceedings of the 9th Python in Science Conference* (hlm. 56–61).

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., … Gebru, T. (2019). Model cards for model reporting. Dalam *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT* '19)* (hlm. 220–229). ACM. https://doi.org/10.1145/3287560.3287596

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., … Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

van der Maaten, L., & Hinton, G. (2008). Visualizing data using t-SNE. *Journal of Machine Learning Research, 9*, 2579–2605.

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., … SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods, 17*, 261–272. https://doi.org/10.1038/s41592-019-0686-2

von Luxburg, U. (2010). Clustering stability: An overview. *Foundations and Trends in Machine Learning, 2*(3), 235–274. https://doi.org/10.1561/2200000008

Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association, 58*(301), 236–244. https://doi.org/10.1080/01621459.1963.10500845

Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software, 6*(60), 3021. https://doi.org/10.21105/joss.03021

BAGIAN B. TAUTAN

Seluruh tautan berikut harus dapat dibuka tanpa meminta akses.

Tabel 43. Daftar tautan proyek

No	Tautan	URL / keterangan
1	Source code (GitHub)	https://github.com/NurihsanFebrianto/A17-Segmentasi_Produk
2	Notebook eksperimen (Colab/Drive)	https://colab.research.google.com/drive/1U4qnMwbKq-DBu8xgSuwdmPtxNPPXmDV1?usp=sharing
3	Dataset sumber (UCI)	https://archive.ics.uci.edu/dataset/502/online+retail+ii
4	Dataset salinan yang dipakai (Kaggle)	https://www.kaggle.com/datasets/adilhabib/online-retail-data-clustering